


Model predictiu de la utilització de recursos sanitaris



Universitat
Oberta
de Catalunya

Manuel Vázquez Martí

Grau de Ciència de Dades Aplicada (GCDA)

Àrea: Analítica predictiva i suport a la decisió

Tutor de TF

Àlfonso Marqués i Cancio

Professora responsable de l'assignatura

Susana Acedo Nadal

Gener de 2026



Aquesta obra està subjecta a una llicència de [Reconeixement 3.0 Espanya de Creative Commons](https://creativecommons.org/licenses/by/3.0/es/)

FITXA DEL TREBALL FINAL

Títol del treball:	<i>Model predictiu de la utilització de recursos sanitaris</i>
Nom de l'autor:	<i>Manuel Vázquez Martí</i>
Nom del director/a:	<i>Alfons Marquès i Cancio</i>
Nom del PRA:	Susana Acedo Nadal
Data de lliurament (mm/aaaa):	01/2026
Titulació o programa:	<i>Grau de Ciència de Dades Aplicada (GCDA)</i>
Àrea del Treball Final:	<i>Analítica predictiva i suport a la decisió</i>
Idioma del treball:	<i>Català</i>
Paraules clau	<i>Salut, predicció, decisió (o recursos)</i>
Resum del Treball	
Aquest treball de fi de grau ha estat realitzat amb la finalitat de poder proporcionar una eina predictiva basada en dades, per estimar la càrrega assistencial futura anual d'altres mèdiques, quirúrgiques i obstètriques en l'atenció hospitalària d'aguts. S'utilitza una metodologia adaptada del procés CRISP-DM, utilitzant dades recopilades de les altes originades pels ingressos hospitalaris d'aguts entre 2018 i 2024 i la respectiva població de referència quinquennal del Servei Català de la Salut (RCA) segons la seva àrea bàsica de salut (ABS) de referència. També s'utilitzen dades de població del mateix RCA com de l'Institut d'Estadística de Catalunya per obtenir projeccions futures. Per al modelat es van entrenar diversos models d'aprenentatge automàtic i boosting amb diferents hiperparàmetres, utilitzant el llenguatge de programació Python. Per avaluar els resultats s'han utilitzat les mètriques MAE, RMSE, R^2 i SMAPE, obtenint amb els models finals un coeficient de determinació R^2 superior al 0.9 en el conjunt total de les dades de validació per cada tipus d'alta. El producte final és un conjunt de models reentrenables si escau, sobre els que es poden aplicar projeccions determinades de poblacions per punts de referència per obtenir les altes corresponents. També s'ha preparat una interfície (TUI) per poder desplegar i executar els scripts de manera autònoma. Com a conclusió podem indicar que la eina desenvolupada permet anticipar la càrrega de recursos, però es recomana que per augmentar la precisió i qualitat, la mateixa institució proporcionï internament les dades preprocessades de projeccions de població.	

Abstract

This Final Degree Project has been carried out with the aim of providing a data-driven predictive tool to estimate the future annual healthcare workload of medical, surgical, and obstetric discharges in acute hospital care. An adapted CRISP-DM methodology is applied, using data collected from discharges originating from acute hospital admissions between 2018 and 2024, and the respective five-year reference population of the Catalan Health Service (RCA) according to its basic health area (ABS) of reference. Population data from both CatSalut and the Statistical Institute of Catalonia are also used to obtain future population projections.

For the modelling phase, several machine learning and boosting models were trained with different hyperparameters using the Python programming language. Model performance was evaluated using the MAE, RMSE, R^2 and SMAPE metrics, with the final models achieving a coefficient of determination (R^2) above 0.9 on the full validation dataset for each type of discharge.

The final product is a set of retrainable models if applicable, on which determined population projections by reference points can be applied to obtain the corresponding discharges. In addition, a text-based user interface (TUI) was developed to enable autonomous deployment and execution of the scripts.

In conclusion, the developed tool enables the anticipation of healthcare resource demand; however, to further improve accuracy and quality, it is recommended that the institution internally incorporates preprocessed population projection data.

Agraïments

Vull expressar el meu sincer agraïment a **Alba Benaque Vidal**, gerent de la Gerència d'Organitzacions del Servei Català de la Salut, per haver promogut i impulsat, des de dins de l'organització, la idea d'aquest treball. Sense la seva iniciativa, visió i suport institucional, la realització d'aquesta memòria no hauria estat possible.

Així mateix, vull agrair a **Sílvia Prior Cayuela**, referent tècnic i tutora dins del CatSalut, la seva dedicació, disponibilitat i assessorament continu en l'àmbit tècnic, així com les seves aportacions clau al llarg del desenvolupament del projecte.

Vull fer una menció especial a **Alfons Marquès i Cancio**, director del treball i professor-tutor de la universitat, per la seva guia constant, l'acompanyament acadèmic i les orientacions metodològiques que han estat fonamentals durant tot el procés d'elaboració del Treball de Fi de Grau.

Finalment, vull agrair a la **meva família** la seva paciència, comprensió i suport, així com el temps que els he deixat de dedicar durant el desenvolupament d'aquest treball.

Índex

Llista de figures	vii
1. Introducció.....	1
1.1. Context i justificació del Treball	1
1.1.1. Posada en context	1
1.1.2. Antecedents en models predictius aplicats a la planificació sanitària ..	3
1.1.3. Justificació	4
1.2. Objectius del treball	5
1.2.1. Objectius generals	5
1.2.2. Objectius específics	6
1.2.3. Problemàtica a resoldre	6
1.3. Impacte en sostenibilitat, ètic-social i de diversitat	7
1.3.1. Dimensió de sostenibilitat	8
1.3.2. Dimensió ètica i de responsabilitat social.....	8
1.3.3. Dimensió de diversitat i drets humans	9
1.4. Enfocament i mètode seguit	9
1.4.1. Plantejament inicial de base	10
1.4.2. Mètode de desenvolupament.....	10
1.4.3. Mètode de generació de models.....	12
1.5. Planificació del Treball.....	13
1.5.1. Recursos necessaris.....	13
1.5.2. Tasques planificades	14
1.5.3. Fites (milestones).....	15
1.5.4. Calendari (diagrama de Gantt).....	16
1.5.5. Tasques concordades a les entregues de les PAC	17
1.6. Sumari de productes obtinguts	17
1.6.1. Productes intermedis	17
1.6.2. Productes finals	17
1.6.3. Productes de suport.....	18
1.7. Estructura i contingut de la resta de capítols	18
2. Disseny i desenvolupament de la solució.....	20
2.1. Recollida de dades	20
2.1.1. Projecció de la població	20
2.1.2. Àrees Bàsiques de Salut (ABS)	21
2.1.3. Límits administratius comarcals de Catalunya	21
2.1.4. Taula de relació entre ABS, AGA, Sector sanitari i Regió sanitària ...	21
2.1.5. Recollida de la població per àrea bàsica de salut. Registre central de població del CatSalut	22
2.1.6. Recollida del nombre d'ingressos hospitalaris catalogats segons tipus d'alta (mèdica, quirúrgica i obstètrica).....	22
2.2. Preparació de l'entorn de treball.....	23
2.2.1. Creació d'un entorn virtual de Python	23
2.2.2. Desplegament d'arxius de la solució i creació de carpetes.....	23
2.3. Neteja i preparació de dades.....	24
2.3.1. Processar projeccions de població	25

2.3.2.	Mapeig territorial de les ABS.....	25
2.3.3.	Mapeig de les AGA (Àrees de Gestió Assistencial) amb les ABS.....	26
2.3.4.	Depuració de la població RCA (Registre Central d'Assegurats)	26
2.3.5.	Processament i mapeig d'altres anuals per ABS	27
2.3.6.	Generació de projeccions de població per ABS	27
2.4.	Modelització i eina d'inferència (predictor).....	28
2.4.1.	Consideracions prèvies.....	28
2.4.2.	Procés de modelització (elecció i entrenament de models)	30
2.4.3.	Realitzar la predicció (inferència) de les dades.....	32
2.4.4.	'Frontend' per executar els scripts	32
2.4.5.	Productes generats i obtinguts.....	35
3.	Resultats i validació dels models	37
3.1.	Conclusions de l'informe i mètriques	37
3.1.1.	Resultats globals.....	37
3.1.2.	Resultats a nivell de regió sanitària.....	38
3.1.3.	Resultats a nivell de sector sanitari.....	40
3.1.4.	Resultats a nivell d'àrees de gestió assistencial (AGA)	41
3.1.5.	Resultats a nivell d'Àrees bàsiques de salut (ABS).....	42
3.1.6.	Robustesa dels models i adequació a l'objectiu de compra sanitària	42
3.1.7.	Conclusions finals (síntesi)	43
3.2.	Anàlisi d'interpretabilitat SHAP dels models	43
3.2.1.	Motivació de la interpretabilitat en models predictius sanitaris.....	43
3.2.2.	Fonaments teòrics de SHAP	44
3.2.3.	Interpretabilitat global: importància mitjana de les variables	44
3.2.4.	Interpretabilitat local i anàlisi de dependència.....	45
3.2.5.	Valor afegit de SHAP per a la planificació sanitària	45
3.2.6.	Importància de les característiques.....	45
3.2.7.	Mapes de calor, comparativa a nivell global	48
3.2.8.	Mapes de calor, anàlisis SHAP per sexe (valor absolut).....	49
3.2.9.	Mapes de calor, anàlisis SHAP per sexe (valor signat).....	51
3.2.10.	Partial dependence plots	52
3.2.11.	Aportació de cada variable (waterfall)	55
3.3.	Resum final de tota la interpretació	58
3.3.1.	Comportament de les mètriques segons el nivell d'agregació	59
3.3.2.	Robustesa del model i adequació a l'objectiu de planificació.....	59
3.3.3.	Contribució de l'anàlisi SHAP a la interpretació dels resultats	59
3.3.4.	Conclusió final.....	60
4.	Conclusions i treballs futurs	61
4.1.	Conclusions generals del treball.....	61
4.2.	Assoliment dels objectius plantejats	62
4.3.	Seguiment de la planificació i adequació de la metodologia.....	62
4.4.	Avaluació dels impactes ètic-socials, de sostenibilitat i de diversitat.....	63
4.5.	Impactes no previstos.....	63
4.6.	Línies de treball futur	64
5.	Glossari	65
6.	Bibliografia	66
7.	Annexos	70
	Annex A. Recomanacions del director del treball - tutor.....	70

Llista de figures

Figura 1-1	Contractació altes Hospital General de Vic, 2022	2
Figura 1-2	Evolució d'envelliment i dependència.....	4
Figura 1-3	Objectius de Desenvolupament Sostenible.....	7
Figura 1-4	Adaptació de la metodologia CRISP-DM al projecte.....	9
Figura 1-5	Elecció de programari i models	10
Figura 1-6	Productes obtinguts	18
Figura 2-1	Recollida de les dades necessàries en paral·lel	20
Figura 2-2	Estructura inicial al desplegar les carpetes i els arxius	23
Figura 2-3	Estructura final al realitzar-se el preprocés de dades	24
Figura 2-4	Neteja i preparació de les dades de manera consecutiva	25
Figura 2-5	Procés per a la selecció de models d'aprenentatge automàtic	28
Figura 2-6	Accés directe des de consola.....	33
Figura 2-7	Frontend en un navegador implantat en una màquina MX Linux ..	33
Figura 3-1	Importància de les característiques pel tipus d'alta mèdica	46
Figura 3-2	Importància de les característiques pel tipus d'alta obstètrica	46
Figura 3-3	Importància de les característiques pel tipus d'alta quirúrgica	47
Figura 3-4	Mapes de calor absolut de característiques dels 3 tipus d'alta	48
Figura 3-5	Mapes de calor absolut per sexe pels 3 tipus d'alta	49
Figura 3-6	Mapes de calor signat per sexe pels 3 tipus d'alta	51
Figura 3-7	PDP "Dones de 75 a 79 anys" pel tipus d'alta mèdica	53
Figura 3-8	PDP "Dones de 0 a 4 anys" pel tipus d'alta obstètrica	54
Figura 3-9	PDP "Homes de 30 a 34 anys" pel tipus d'alta quirúrgica	55
Figura 3-10	Aportació a l'ABS de mostra pel tipus d'alta mèdica	56
Figura 3-11	Aportació a l'ABS de mostra pel tipus d'alta quirúrgica	57
Figura 3-12	Aportació a l'ABS de mostra pel tipus d'alta obstètrica	58

1. Introducció

El sistema sanitari públic català, afronta actualment un escenari de transformació profunda, marcat per l'envelliment progressiu de la població, l'augment de la cronicitat, la pressió sobre la despesa pública i una demanda assistencial cada cop més complexa i heterogènia.

En aquest context, la presa de decisions basada exclusivament en criteris històrics o intuïtius resulta insuficient per garantir una planificació eficient, equitativa i sostenible dels recursos sanitaris.

La disponibilitat creixent de dades clíniques, demogràfiques i territorials, juntament amb els avenços en ciència de dades i aprenentatge automàtic, obre noves oportunitats per anticipar necessitats futures i donar suport a la gestió estratègica dels sistemes de salut.

L'anàlisi predictiva esdevé així una eina clau per millorar la capacitat de resposta del sistema sanitari davant escenaris canviants, minimitzar ineficiències i optimitzar l'assignació de recursos públics.

Aquest Treball de Fi de Grau s'emmarca en aquesta línia, amb l'objectiu de desenvolupar una aproximació basada en dades per a la previsió de l'activitat hospitalària d'aguts, contribuint a una millor planificació de la contractació sanitària. A partir d'aquest plantejament general, en els apartats següents es descriu el context específic del treball, els objectius que es persegueixen i l'impacte potencial de la proposta des d'una perspectiva organitzativa, social i ètica.

1.1. Context i justificació del Treball

1.1.1. Posada en context

La despesa pública és essencial per al funcionament eficient del govern i l'administració, ja que permet oferir serveis bàsics a la ciutadania. No obstant això, aquesta despesa ha d'estar ben planificada i controlada per garantir-ne l'eficiència, evitar el malbaratament i assegurar una gestió responsable dels recursos col·lectius. En aquest sentit, el control de la **despesa sanitària** és especialment rellevant, ja que representa una part significativa del pressupost públic i té un impacte directe en el benestar i la salut de la població.

Catalunya es caracteritza per una organització sanitària territorial que busca adaptar-se a les necessitats reals de la ciutadania. Aquesta estructura evoluciona amb el temps i es basa en una divisió per **regions sanitàries** (en el seu nivell d'agregació geogràfic superior) fins les **àrees bàsiques de salut (ABS)**, que defineixen els àmbits d'actuació dels proveïdors sanitaris. Per tal de garantir la cobertura adequada a tot el territori, el **Servei Català de la Salut (CatSalut)** formalitza contractes amb proveïdors públics i privats (Institut Català de la Salut (ICS), consorcis, fundacions) ⁽¹⁾ per mitjà de convenis que fixen l'activitat prevista i els recursos associats.

Aquest model mixt integra tots els recursos sanitaris —públics i concertats— en una xarxa única, i estableix, per a cada centre, el volum d'activitat per línies assistencials (mèdiques, quirúrgiques, obstètriques...), juntament amb el preu unitari corresponent) ⁽²⁾. La **retribució hospitalària** es determina pel producte del nombre d'altres per tipus pel seu valor econòmic ponderat, d'acord amb la complexitat assistencial ⁽³⁾.

Per això, la **planificació de la contractació sanitària** requereix previsions anuals acurades sobre la demanda prevista d'altres hospitalàries. Aquesta previsió permet optimitzar la despesa i assegurar una assignació eficient de recursos com llits, personal mèdic i equipament. A Catalunya hi ha més de 400 centres d'atenció primària i 68 hospitals amb ús públic. D'aquests, un gran percentatge d'altres (especialment agudes) es produeix en el sector concertat amb CatSalut. Per exemple, un informe del Consorci Hospitalari de Vic assenyala que el concertat suposa gairebé el 74% de les altres d'aguts a Catalunya i més del 50% del concertat a l'hospital (clàusula de 2022). Cada conveni estableix pesos i import unitari per tipus d'alta: en un acord recent, una alta quirúrgica tenia factor 1,1296 (superior al cost base de 958,20 €), mentre que una alta obstètrica pesava només 0,4184 ⁽⁴⁾. Aquest desequilibri reflecteix la diferent complexitat i cost associats. En conjunt, l'objectiu organitzatiu és garantir que la contractació pressupostària (concerts, complements per activitat) s'ajusti a la demanda real esperada de pacients (mèdics, quirúrgics, obstètrics).

Nom i Codi Unitat Proveïdora: Hospital General de Vic, 00745				
Període Clàusula: 1 de gener a 31 de desembre de 2022				
La Llei 5/2020, del 29 d'abril, de mesures fiscals, financeres, administratives i del sector públic i de creació de l'impost sobre les i en el medi ambient, diu en el punt 2 de la Disposició transitòria primera que fins l'entrada en vigor de la llei reguladora de contractuals en matèria de salut, es mantenen els actuals convenis, contractes i concerts per a la provisió de serveis sanitaris primària, d'atenció sociosanitària, d'atenció a la salut mental i d'atenció a les drogodependències.				
Contractació 2022 (inclou les actuacions iniciades al 2022)				
Activitat				
Hospitalització	Nº altres		Preu unitari	
Altes mèdiques	5.521		2.078,58 €	
Altes quirúrgiques	6.813		2.479,58 €	
Altes obstètriques	1.046		1.776,46 €	
Total hospitalització	13.380			
Paràmetres	Nivell		Preu estructura	
Estructura	4		1.375,55 €	
	IRR	Factor de ponderació	Preu unitari mitjà	Preu casuística
Casuística	0,7337	1,00	958,20 €	703,03
Altes mèdiques	1,1296	1,02	958,20 €	1.104,03
Altes quirúrgiques	0,4184	1,00	958,20 €	400,91
Altes obstètriques				

Figura 1-1 Contractació altres Hospital General de Vic, 2022

Font: CatSalut

Troblem un **informe de la Sindicatura de Comptes de Catalunya** d'aquest mateix any 2025, anomenat Sistema de contraprestació dels serveis d'atenció hospitalària i especialitzada d'aguts prestats pels centres del SISCAT per compte del CatSalut, exercici 2022 ⁽⁵⁾, on s'exposa que “**el volum de la despesa desplaçada de l'atenció hospitalària d'aguts realitzada i no registrada al pressupost va ser de 1.078,04 M€, l'any 2022**”.

En aquest context, **la predicció de la càrrega d'altres hospitalàries** pot esdevenir una eina clau per ajustar millor la planificació contractual a les necessitats reals de la població i, alhora, garantir una gestió més eficient i sostenible de la despesa sanitària.

1.1.2. Antecedents en models predictius aplicats a la planificació sanitària

Diversos estudis han demostrat que els models basats en l'**Aprenentatge Automàtic** (Machine Learning) poden predir amb precisió diagnòstics, estada, mortalitat i reingrés a partir de dades clíniques inicials. Cal destacar, que **molts d'aquests anàlisis** d'estudis, **estan realitzats sobre diversos conjunts de dades del MIMIC** (Medical Information Mart for Intensive Care), del qual el conjunt de dades més utilitzat és el de MIMIC-III ^(6,7).

Es presenta una petita mostra d'aquests estudis:

1. **Predicció de mortalitat a l'ingrés a la planta mèdica.**
Un model amb dades de laboratori i variables demogràfiques va assolir un AUC (àrea sota la corba) de 0,924 en predir la mortalitat hospitalària a l'ingrés, destacant com el ML supera mètodes tradicionals ^(8,9).
2. **Predicció de mortalitat en UCI amb MIMIC-III.**
En pacients amb insuficiència cardíaca a UCI, un model XGBoost va obtenir un AUC (àrea sota la corba) de 0,84, mostrant la potència del ML per predir pronòstic crític ⁽¹⁰⁾.
3. **Predicció del risc d'ingrés urgent (emergency admission).**
A partir de dades de 4,6 milions de pacients al Regne Unit, un model de gradient boosting va millorar l'AUC de 0,74 a 0,85 respecte als models clàssics, demostrant robustesa a llarg horitzó (fins a 5 anys) ⁽¹¹⁾.
4. **Predicció d'ingrés hospitalari des de urgències (ED).**
En un estudi multicèntric a França, un model XGBoost va permetre predir el nombre d'ingressos hospitalaris amb un error mitjà absolut de 2,6 admissions mensuals i valors d'AUC compresos entre 0,90 i 0,93, mostrant la utilitat del *machine learning* en la gestió operativa dels serveis d'urgències ⁽¹²⁾.
5. **Auto mapatge de diagnòstics a partir de notes clíniques (MIMIC-III).**
Mitjançant tècniques de processament del llenguatge natural (NLP), un estudi va aconseguir predir el top-10 de codis ICD-9 amb una precisió propera al 80 % a partir de notes clíniques no estructurades, evidenciant el potencial de les dades textuais en entorns hospitalaris ⁽¹³⁾.

6. Predicció de la demanda de serveis sanitaris mitjançant models híbrids.

Huang et al. proposen un model híbrid basat en ARIMA combinat amb un mecanisme de filtratge auto-adaptatiu per predir el volum diari de visites externes. Els resultats mostren una millora significativa en la precisió respecte als models de sèries temporals tradicionals, destacant el valor d'aquests enfocaments per a la planificació de recursos sanitaris [\(14\)](#).

7. Predicció del volum d'activitat ambulatoria amb *machine learning*.

Un estudi recent aplica l'algoritme XGBoost per predir el volum diari de visites externes hospitalàries, incorporant variables temporals, meteorològiques i de disponibilitat de personal mèdic. Els resultats indiquen un rendiment superior als models estadístics clàssics, reforçant la utilitat del *machine learning* en la planificació sanitària [\(15\)](#).

8. Predicció de la demanda de llits hospitalaris.

Altres treballs han utilitzat models d'aprenentatge automàtic per anticipar la demanda de llits d'hospitalització, un indicador clau per a la gestió de capacitat. Aquests models permeten donar suport a la presa de decisions operatives i estratègiques en contextos de variabilitat elevada de la demanda [\(16\)](#).

9. Models predictius d'ingressos no planificats: revisió sistemàtica.

Una revisió sistemàtica centrada en persones grans que viuen a la comunitat analitza diferents models predictius d'ingrés hospitalari no planificat. Tot i que el rendiment és moderat en molts casos, l'estudi posa de manifest el potencial d'aquests models i la necessitat de millorar-ne la metodologia per facilitar-ne l'aplicació en la planificació sanitària [\(17\)](#).

1.1.3. Justificació

La planificació i gestió dels recursos sanitaris constitueixen un àmbit estratègic per al bon funcionament del sistema de salut, especialment en un context marcat per l'envelliment poblacional, l'increment de la cronicitat i la limitació dels recursos públics disponibles.




Figura 1-2 Evolució d'envelliment i dependència

Font: Idescat. Indicadors demogràfics

En aquest escenari, disposar d'eines predictives basades en dades que permetin anticipar la demanda assistencial esdevé fonamental per millorar l'eficiència organitzativa, reduir ineficiències i garantir una assignació més equitativa dels recursos sanitaris.

Aquest treball es justifica per la necessitat d'explorar l'aplicació de tècniques d'anàlisi predictiva i aprenentatge automàtic en l'àmbit de la planificació sanitària, amb especial atenció a l'activitat hospitalària d'aguts, un dels principals determinants de la despesa i de la capacitat assistencial del sistema.

Com a motivació addicional afegida, ja que a banda de ser usuari del sistema sanitari català, també en formo part com a professional.

1.2. Objectius del treball

1.2.1. Objectius generals

D'acord amb els objectius estratègics establerts per la pròpia institució, el propòsit d'aquest estudi és analitzar la relació existent entre l'evolució demogràfica de la població i la distribució territorial de les altes de cada tipus generades en l'àmbit hospitalari d'aguts. Aquesta anàlisi pretén identificar possibles patrons o correlacions que permetin estimar, amb un cert grau de fiabilitat, la càrrega assistencial futura per tipologia d'alta i per territori, facilitant així una planificació més eficient dels recursos sanitaris.

Com a fase inicial d'aquest projecte, i amb voluntat d'assentar una metodologia aplicable en altres àmbits, el focus analític es centrarà en el marc de l'atenció especialitzada i hospitalària d'aguts [\(18\)](#). L'objectiu específic d'aquesta primera etapa és proporcionar al Servei Català de la Salut (CatSalut) una eina predictiva basada en dades que permeti anticipar, a mig i llarg termini, les necessitats d'altes mèdiques, quirúrgiques i obstètriques, a partir dels ingressos hospitalaris anuals de la població a càrrec del CatSalut. Aquesta informació pot contribuir a la presa de decisions estratègiques en la distribució de recursos, la gestió de la capacitat hospitalària i l'assignació territorial dels serveis.

La planificació sanitària fonamentada en projeccions demogràfiques i epidemiològiques és àmpliament reconeguda com una pràctica essencial per garantir la sostenibilitat i eficiència dels sistemes de salut (Birch et al., 2007 [\(19\)](#)). En aquest sentit, l'ús d'eines d'anàlisi predictiva i modelització pot millorar significativament la capacitat de resposta del sistema davant les transformacions socials i sanitàries que es deriven, entre altres factors, de l'envelliment poblacional, l'increment de les malalties cròniques o la variabilitat territorial de la demanda assistencial.

1.2.2. Objectius específics

Els primers dos punts són l'objectiu metodològic, que es vol intentar assolir.

- Seleccionar i avaluar models predictius: Investigar i comparar diferents models d'aprenentatge automàtic (com LTSM i XGBoost, tal com s'esmenta en la documentació) per determinar quins són els més adequats per a la predicció de la utilització de recursos sanitaris, considerant la natura de les dades (sèries temporals, categòriques, etc.).
- Desenvolupar i validar un model predictiu: Implementar, entrenar i validar un model d'aprenentatge automàtic utilitzant dades històriques de la utilització de recursos sanitaris, assegurant la seva precisió i fiabilitat. Es farà èmfasi en la gestió de possibles desequilibris en els resultats a causa de la variabilitat territorial. Serà força important fer contrastos de resultats entre diferents nivells (ABS, AGA, Sectors Sanitaris i Regions Sanitàries)

Proposar recomanacions per a la implementació: Elaborar un conjunt de recomanacions tècniques i ètiques per a la integració del model predictiu en el sistema de gestió de recursos sanitaris del CatSalut, incloent consideracions sobre escalabilitat i manteniment.

1.2.3. Problemàtica a resoldre

Es considera com objectiu, quina és la problemàtica a resoldre com una altra finalitat, ja que a banda d'una eina predictiva, es volen reduir els biaixos potencials, ja que una planificació incorrecta pot comportar dues situacions igualment problemàtiques: d'una banda, la sobre assignació de recursos, amb el consegüent malbaratament de mitjans humans o materials; de l'altra, una manca de previsió que obliga a una mobilització urgent i no planificada de recursos que, tot i no ser considerats d'emergència, haurien d'haver estat previstos en escenaris normals.

Aquest darrer cas pot generar tensions operatives i ineficiències greus, especialment en contextos delicats com el d'una pandèmia, però també en el dia a dia del sistema sanitari.

Aquest repte s'agreuja en el context actual, marcat per un envelliment progressiu de la població i per l'increment sostingut de les malalties cròniques, que generen una pressió constant i creixent sobre el sistema sanitari. Segons dades de l'Observatori Social de "la Caixa" [\(20\)](#), prop del 70% de les persones majors de 65 anys a Espanya pateixen alguna malaltia crònica diagnosticada, en contrast amb menys d'una de cada tres persones en la població general. A més, les projeccions de l'Institut Nacional d'Estadística indiquen que per al 2031, el nombre de persones majors de 65 anys a Espanya arribarà als 11,7 milions, un augment del 34,72% respecte a l'actualitat, plantejats en una ponència del Parlament de les Illes Balears [\(21\)](#).

Un altra fet a tenir en compte és que segons l'Institut d'Estadística de Catalunya (IDESCAT) ⁽²²⁾, l'any 2023 es van registrar 54.217 naixements a Catalunya, un descens del 3,8% respecte a l'any anterior. A nivell estatal, Espanya va registrar 320.656 naixements el mateix any, amb una disminució del 2,6%. A més, l'índex conjuntural de fecunditat a Catalunya s'ha situat en 1,11 fills per dona el 2023, el valor més baix registrat fins ara i inferior a la mitjana de la zona euro (1,45 fills per dona) ⁽²³⁾.

En aquest escenari, es fa evident la necessitat de replantejar els models tradicionals de provisió i assignació de recursos, tot plantejant si ens trobem davant d'un veritable canvi de paradigma en la manera d'entendre la planificació i la gestió sanitària. La incertesa associada a aquesta possible transformació obliga a incorporar noves eines de predicció, anàlisi de dades i presa de decisions, que permetin adaptar el sistema a realitats emergents amb criteris d'eficiència, equitat i sostenibilitat.

1.3. Impacte en sostenibilitat, ètic-social i de diversitat

En aquest apartat analitzem els impactes potencials del Treball de Fi de Grau en relació amb les tres dimensions de la competència transversal de la UOC “*Compromís ètic i global*”: sostenibilitat, comportament ètic i responsabilitat social, i diversitat i drets humans, d'acord amb les orientacions recollides a la *Guia transversal sobre la CCEG*.



Figura 1-3 Objectius de Desenvolupament Sostenible
Font: United Nations – SDGs

1.3.1. Dimensió de sostenibilitat

El treball **té un impacte indirecte però positiu** en termes de sostenibilitat. El desenvolupament d'un model predictiu per a la previsió de l'activitat hospitalària d'aguts permet millorar la planificació de la contractació sanitària i, en conseqüència, **optimitzar l'ús dels recursos públics disponibles**.

Una millor anticipació de la demanda assistencial pot contribuir a reduir tant situacions de sobre-assignació com de sots-assignació, fet que comporta un ús més eficient de les infraestructures existents i una reducció de consums innecessaris associats a una planificació reactiva. Aquest enfocament s'alinea especialment amb l'**ODS 12 (Producció i consum responsables)** i l'**ODS 9 (Indústria, innovació i infraestructures)**, en promoure *processos de decisió* basats en dades i una *gestió més eficient* dels sistemes complexos.

Pel que fa al desenvolupament del projecte, l'impacte ambiental directe és limitat, ja que el treball es basa en l'anàlisi de dades existents i en l'ús d'eines informàtiques estàndard i a l'abast de tothom. A banda d'això, les tecnologies i llenguatges de programació són àmpliament utilitzats i per tant constantment optimitzats per ser eficients. Per tant, es minimitza el consum computacional innecessari i el fet d'afavorir la reutilització futura dels models desenvolupats (pel que si no es vol no cal re-entrenar de nou), en resulta una eina amb baix consum energètic.

1.3.2. Dimensió ètica i de responsabilitat social

Des del punt de vista ètic i de responsabilitat social, el treball presenta un impacte positiu rellevant, atès que el seu objectiu principal és contribuir a una millor gestió d'un servei essencial com és el sistema sanitari públic.

L'ús de models predictius per anticipar la demanda d'altres hospitalàries pot ajudar a millorar l'equitat en l'assignació de recursos, reduir desigualtats territorials i minimitzar situacions de tensió assistencial derivades d'una planificació insuficient. En aquest sentit, **el treball s'alinea amb l'ODS 16 (Institucions sòlides i eficaces)**, en promoure una presa de decisions més transparent, basada en evidències i orientada al bé comú.

Pel que fa a l'ús de dades, el projecte utilitza exclusivament dades agregades i anonimitzades, procedents de fonts oficials, evitant qualsevol tractament de dades personals o sensibles. Aquesta decisió metodològica garanteix el compliment dels principis de privacitat, confidencialitat i protecció de dades, i minimitza els riscos associats a un ús indegut de la informació.

Tanmateix, es reconeix que l'ús de models predictius pot comportar riscos potencials si s'utilitzen de manera acrítica o com a únic criteri de decisió. Per aquest motiu, el treball planteja el model com una eina de suport a la decisió, i no com un mecanisme automàtic de substitució del criteri professional o institucional, incorporant així una visió ètica i responsable de la seva aplicació.

No vol ser una eina d'assignació, sinó de detecció de necessitats per territori per ajudar a decidir als professionals responsables quin serien els millors concerts a aplicar a l'hora de planificar la contractació.

1.3.3. Dimensió de diversitat i drets humans

En relació amb la diversitat i els drets humans, el treball no presenta impactes negatius directes, però sí un potencial impacte positiu indirecte. El model predictiu es construeix a partir de dades poblacionals i territorials agregades, sense distincions per raó de gènere (es classifiquen de manera "cega"), origen, condició socioeconòmica o altres característiques personals, evitant així qualsevol forma de discriminació explícita en el disseny de la solució.

A més, la millora en la planificació de recursos sanitaris pot contribuir a reduir desigualtats d'accés als serveis de salut entre diferents territoris o col·lectius, especialment en contextos amb una elevada pressió assistencial. Aquest enfocament s'alinea amb l'**ODS 10 (Reducció de les desigualtats)** i, de manera indirecta, amb l'**ODS 5 (Igualtat de gènere)**, en tant que l'accés equitatiu als serveis sanitaris és un factor clau per a la igualtat d'oportunitats, ja que les dades, encara que no estan etiquetades de manera distintiva, el que volen es recollir les necessitats de cada grup d'edat i sexe.

Finalment, en el redactat de la memòria s'ha tingut en compte l'ús d'un llenguatge inclusiu i respectuós, així com una perspectiva àmplia de la diversitat, que no es limita únicament al gènere sinó que considera també altres dimensions com l'edat, l'origen territorial i la situació socioeconòmica.

1.4. Enfocament i mètode seguit

Es presenta en primer terme, l'adaptació del mètode CRISP-DM (Cross-Industry Standard Process for Data Mining), adaptada al context de la planificació sanitària, utilitzat durant tot el projecte, i posteriorment com s'ha escollit el mètode de desenvolupament i de models d'aprenentatge automàtic a fer servir.




Figura 1-4 Adaptació de la metodologia CRISP-DM al projecte

1.4.1. Plantejament inicial de base

Des del primer moment, la idea era desenvolupar un producte nou que, a partir de les dades recollides i mitjançant un algoritme, d'entre varis a avaluar, pogués generar un model a aplicar per obtenir el nombre predit d'altres per anys futurs. A partir d'aquí ens hem de centrar en 2 aspectes (desenvolupament i models) dels quals enlloc d'utilitzar una taula DAFO, enumeraré els aspectes positius i negatius, a l'hora de la seva avaluació.




Figura 1-5 Elecció de programari i models

1.4.2. Mètode de desenvolupament

En quant a quin mètode de desenvolupament es podia utilitzar, s'han avaluat tres eines diferents, els llenguatges de programació R [\(24\)](#) i Python [\(25\)](#), i la eina analítica KNIME [\(26\)](#).

Llenguatge de programació R

Aspectes positius

- Està **dissenyat** específicament **per l'anàlisi estadístic i modelització**.
- Té un **gran repositori** de paquets per treballar, incloent un conjunt força complet en el seu paquet base, però hi ha també de molt interessants com els de les llibreries de *tidyverse* i *caret*.
- És una eina amb un **gran suport acadèmic i científic**, i moltes de les implementacions de modelatge, es fan primer en aquest entorn.

Aspectes negatius

- **Menys facilitat d'integració** en entorns productius.
- **Corba d'aprenentatge menys intuïtiva**.

- **Menys versatilitat** a l'hora de fer implementacions pròpies (funcions, classes...)

Llenguatge de programació Python

Aspectes positius

- **Molt versàtil i repositori molt ampli**, encara que no tant en el mateix paquet base com R, té moltíssims paquets reconeguts i utilitzats arreu.
- Facilitat d'**integració i desplegament**. Es pot implementar en servidors i accedir als seus scripts (o productes que generen) mitjançant contenidors o API (Interfície de Programació d'Aplicacions).
- **Alta llegibilitat i corba d'aprenentatge moderada**. El ser un llenguatge força senzill d'interpretar, és molt fàcil de comprendre el codi tant a l'hora de l'aprenentatge com en la implementació, manteniment i el seu anàlisi acadèmic.

Aspectes negatius

- **Menys orientat a mètodes estadístics clàssics**. Encara que hi ha força implementació, està molts cops menys documentada que en R.
- La **gestió d'entorns i dependències**. S'ha de portar molta cura amb la instal·lació de paquets que poden requerir versions explícites i contraindicar a d'altres, pel que és millor preparar entorns aïllats per cada projecte.
- **Rendiment limitat sense optimització**. Molts de cops es requereix de processadors avançats (GPU – Graphics Processing Unit), per poder executar algorismes d'aprenentatge automàtic. Moltes empreses per això ofereixen el seu servei de recursos de processament al núvol.

Eina analítica KNIME

Aspectes positius

- Entorn visual i intuïtiu. Al ser un entorn modular, és molt fàcil de crear fluxos de treball analítics sense haver de programar.
- Ràpid prototipatge i validació. És molt millor que els “notebooks” de Python i R, per executar blocs específics, sobretot a l'hora de passar valors determinats (podent provenir de tot un flux). Molt útil per validacions ràpides de manera visual.
- Es pot integrar amb Python i R. Suporta nativament (té mòduls directes), programació amb el llenguatge de programació Java, també es poden fer crides al programari citat que tinguem instal·lat [\(27\)](#).

Aspectes negatius

- **Menys flexibilitat per desenvolupament complex**. És el problema de treballar amb mòduls i la manera de passar o mantenir les variables.

- **Dependència de la interfície gràfica.** Encara que avui en dia no ho sembli, aquesta dependència pot ser força greu sobretot en l'aspecte de la implementació.
- **La corba d'aprenentatge és alta,** i moltes vegades la manera millor per avançar és assistir a cursos de la mateixa companyia que desenvolupa el software.

Conclusió de tria final de l'eina de desenvolupament

Després d'avaluar les tres eines i realitzar petites proves preliminars, **es decideix utilitzar Python** com a eina de programació, degut a la facilitat que ofereixen més eines a crear entorns virtuals i el seu desplegament.

Encara que el coneixement de les altres dos eines és exhaustiu, i havent generat solucions en ambdues, es considera que és una tecnologia en la qual avui en dia s'aposta molt més per Python en l'àmbit d'aprenentatge automàtic i el seu llenguatge és més interpretable en un treball de fi de grau.

1.4.3. Mètode de generació de models

En el procés de selecció dels models predictius, es van avaluar diverses famílies de models, incloent-hi models basats en sèries temporals, models d'aprenentatge automàtic basats en *boosting* i models d'aprenentatge profund. Aquesta avaluació s'ha dut a terme tenint en compte tant criteris tècnics com criteris de viabilitat i adequació al context organitzatiu del sistema sanitari.

En primer lloc, els models clàssics de sèries temporals (com ARIMA, VAR o similars) van ser considerats inicialment al moment de preparar la contextualització del Treball de fi de grau com una opció natural, atès que l'objectiu principal del treball és la previsió de càrrega assistencial futura. No obstant això, aquests models requereixen habitualment sèries temporals amb una longitud suficient per capturar patrons estacionals, tendències i dependències temporals de manera robusta. En aquest treball, la disponibilitat de dades requereix que la granularitat temporal sigui de caràcter anual amb només set observacions per sèrie (2018 – 2024), fet que dificulta significativament l'estimació fiable dels paràmetres i incrementa el risc d'ajustaments poc robustos o inestables. **Per aquest motiu, l'ús de models estrictament temporals va ser descartat.**

En segon lloc, també es van valorar models d'aprenentatge profund, com ara xarxes neuronals recurrents (LSTM o architectures similars), que són especialment potents per a la modelització de dependències temporals complexes. Tot i això, aquests models presenten una elevada complexitat computacional i un nombre considerable de paràmetres a entrenar, la qual cosa els fa especialment sensibles a la quantitat de dades disponibles. En un

escenari amb poques observacions històriques, existeix un alt risc de sobre ajustament, així com una dificultat afegida en la interpretabilitat dels resultats, un aspecte rellevant en un entorn com el de la planificació i la contractació sanitària. Per aquests motius, els models d'aprenentatge profund també van ser descartats.

Davant d'aquestes limitacions, **els models basats en boosting** (com LightGBM o XGBoost) **s'han revelat com una solució especialment adequada**. Aquests models permeten treballar eficientment amb conjunts de dades de mida moderada, són capaços de capturar relacions no lineals entre variables i admeten la incorporació de múltiples variables explicatives més enllà del component temporal. Aquest fet és especialment rellevant en el context del TFG, on la previsió de les altes hospitalàries no depèn únicament del temps, sinó també de factors estructurals, organitzatius i territorials. A més, els models de *boosting* ofereixen un bon equilibri entre capacitat predictiva i interpretabilitat, mitjançant eines com la importància de variables o anàlisis basades en *feature importance*. Aquesta característica facilita la comprensió dels factors que influeixen en la previsió, un aspecte clau per a la seva possible integració en processos de presa de decisions dins del CatSalut i en la planificació de la contractació sanitària.

Conclusió de tria final dels tipus de models.

Tot i que la idea inicial del treball contemplava l'ús de models de sèries temporals, les restriccions derivades de la disponibilitat i la granularitat de les dades han fet escollir l'aproximació més flexible. En aquest sentit, **els models de *boosting* han permès assolir els objectius del projecte**, proporcionant prediccions robustes, interpretables i alineades amb les necessitats reals de l'entorn organitzatiu i de governança del sistema sanitari.

Afegir també en aquest apartat, que es va avaluar l'ús d'un sol model per predir tots els tipus d'altres, però finalment s'ha decidit que es valori independentment (segons mètriques obtingudes) quin model i quins hiperparàmetres s'ajusten millor a cada tipus d'alta. També s'incorpora com a model a avaluar el de regressió lineal estàndard, per tenir una referència de com els models de *boosting* aporten una millora substancial en els resultats obtinguts.

1.5. Planificació del Treball

1.5.1. Recursos necessaris

Es pot citar com a textualment recursos els següents.

- Un maquinari físic o al núvol, on poder implantar l'entorn de treball (Llenguatge de programació Python) i les llibreries necessàries.

- Un editor en el qual es sigui capaç d'editar de programar notebooks i scripts de Visual Studio Code o un dels seus "forks" anomenats VSCodium.
- Talls anuals de la població assegurada a càrrec del CatSalut, per grups d'edat quinquennal, sexe i ABS.
- Les dades geogràfiques de les ABS i de les comarques.
- Les altes mèdiques, obstètriques i quirúrgiques anuals dels hospitals d'aguts, dels usuaris assegurats pel CatSalut.
- Projeccions de població per ABS (per predir situacions futures).

Primera problemàtica trobada a l'iniciar el desenvolupament del treball

Quan es va contextualitzar el TFG, la idea inicial amb més pes era realitzar sèries temporals i utilitzar *lag features* per poder predir les altes futures, però tal com hem vist a l'hora d'escollir el tipus de models a utilitzar, la granularitat temporal a utilitzar és per anys i solament tenim set sèries. Per tant quedava descartada la idea de variables inicial, que es basava en utilitzar els diagnòstics principals i grups ètnics, ja que no el podríem tenir sobre les projeccions i aportaria moltes característiques, amb pocs valors. Per aquest motiu s'ha decidit finalment utilitzar unes característiques de les quals puc obtenir projeccions, i la referència geogràfica de les ABS.

Aquest canvi reflecteix la primera regla d'or del tutor des de que va començar a supervisar la contextualització: **"sempre hem de tenir un pla B"**. de grau.

1.5.2. Tasques planificades

***Nota:** Tant les tasques com les fites planificades, varien en la evolució i execució posterior envers al calendari, ja que estaven pensades més per un semestre de "cinc mesos", i han hagut addicions posteriors per suggeriment del Tutor. El que es mostra és el calendari planificat.*

En el capítol 2 es mostrarà la evolució real del treball.

- **Fase 1: Preparació i recollida de dades (Dia 0 fins dia 18-20, mes 1).** Tasques: Revisió bibliogràfica, obtenció de dades sanitàries (grups de diagnòstics per territoris), obtenció de dades demogràfiques (població per grups d'edat, sexe i territori), dades geogràfiques dels territoris. Configuració de l'entorn de treball (editor, Python i llibreries necessàries).
- **Fase 2: Anàlisi exploratòria i processament de dades (Dia 20, mes 1 fins al dia 12, mes 2).** Tasques: Anàlisi exploratòria de dades (EDA): detecció de patrons, anomalies, valors perduts. Neteja de dades, gestió de valors nuls i reunificació de variables. Enginyeria de característiques (creació de variables rellevants). Escalat i normalització de variables (en principi pot no ser necessari).

- **Fase 3: Modelatge, validació i comparació de models (Dia 13, mes 2 fins al final del mes 3).** Tasques: Creació de conjunts d'entrenament i prova, optimització d'hiperparàmetres, re definició de conjunts si escau, entrenament de models candidats, avaluació dels resultats, anàlisi d'explicabilitat, mitigació de biaixos i selecció del model final.
- **Fase 4: Elaboració de resultats, interpretació i visualitzacions (Dia 1, mes 4 fins al dia 12, mes 4).** Tasques: Preparació de gràfiques, anàlisis del model i preparació de recomanacions.
- **Fase 5: Redacció de la memòria i preparació de la defensa (Dia 13, mes 4 fins al dia 5-10, mes 5).** Tasques: Redacció i revisió de la memòria, preparació d'infografies, documents tècnics, i la presentació per a la defensa.

***Nota:** la finalització de les fases 4, i 5 poden avançar-se segons l'evolució del projecte.*

1.5.3. Fites (milestones)

***Nota:** Anticipo aquest apartat al del calendari, ja que aquest darrer incorporarà tant les fases com les fites.*

Les fites principals, coincideixen amb els finals de fases.

Dia 20 del Mes 1: Dades obtingudes i entorn configurat per començar a treballar.

Dia 15 del Mes 2: Dades processades i conjunts d'entrenament preparats.


Dia 28 del Mes 3: Es decideix el model final.

Dia 13 del Mes 4: S'inicia la redacció de la memòria del TFG i resta de lliurables.

Dia 10 del Mes 5: Tot el projecte finalitzat i preparat per realitzar la defensa del TFG.

1.5.4. Calendari (diagrama de Gantt)

Adjunto gràfica del diagrama de Gantt (realitzada amb GanttProject [\(28\)](#)) i adjunto el PDF del calendari complert en un document independent.



1.5.5. Tasques concordades a les entregues de les PAC

PAC 2

Fase 1: Preparació i recollida de dades

- Realitzada entre el 25/09/2025 i el 10/10/2025

Dades i entorn configurat (fita)

Fase 2: Anàlisi i processament de dades

- Realitzada entre el 11/10/2025 i el 28/10/2025

PAC 3

Fase 3: Modelatge, validació i comparació de models

- Realitzada entre el 29/10/2025 i el 03/11/2025 (primera part)

Dades i conjunts processats (fita)

- Selecció d'hiperparàmetres, entrenament i avaluació
- Aquesta segona part es realitza entre el 04/11/2025 i el 16/11/2025

Elecció de models (fita)

Fase 4: Elaboració de resultats i visualitzacions

- Realitzada entre el 17/11/2025 i el 22/11/2025

Preparació d'un frontend per facilitar l'execució del producte (extensió funcional)

- Realitzat entre el 23/11/2025 i el 02/12/2025
- Ha estat un suggeriment del tutor que ha enriquit el producte

PAC4 (Fase actual)

Fase 5: Redacció de la memòria i presentació

- Data prevista d'entrega: 08/01/2026
- Es **trasllada de la fase 4** la realització de l'informe de recomanacions.

1.6. Sumari de productes obtinguts

En aquest apartat podem considerar 2 tipus: els productes que ajuden a obtenir la resta de productes, i els productes finals.

1.6.1. Productes intermedis

- Notebooks i scripts equivalents per realitzar la manipulació de les dades (ETL)
- Taules de dades temporals per entrenar i avaluar els models.
- Document de requeriments de paquets per la implantació del producte.

1.6.2. Productes finals

- Arxiu amb els models seleccionats per la predicció d'altres hospitalàries.
- Arxiu amb els conjunts de dades d'entrenament i validació dels models.
- Notebook i script per la generació dels models.
- Informe d'anàlisi en format .xlsx generat per el script anterior.

- Document en formats .xlsx i .csv d'anàlisi i *scoring* de mètriques dels models obtinguts amb el script anterior.
- Notebook i script per la predicció d'altres a partir dels models.
- Taules de prediccions en formats .csv i .xlsx de diferents projeccions.
- Interfície gràfica textual (TUI) per executar el producte des de un entorn visual amigable.

1.6.3. Productes de suport

Hi ha productes que es consideren de suport, ja que la seva finalitat no eren ni obtenir elements futurs del producte, sinó proveir informació addicional a la memòria. Per exemple:

- Notebook per generar gràfiques d'interpretabilitat SHAP [\(29\)](#)
- Gràfiques generades pel notebook anterior.




Figura 1-6 Productes obtinguts

1.7. Estructura i contingut de la resta de capítols

- **Disseny i desenvolupament de la solució**
En el capítol 2 es detalla el procés del desenvolupament, incloent la metodologia emprada, les decisions tècniques preses i els components implementats (notebooks, scripts, model predictiu i interfície TUI).
- **Resultats i validació**
El capítol 3 presenta els resultats obtinguts, incloent l'avaluació del model predictiu, les mètriques de rendiment i una anàlisi d'interpretabilitat mitjançant tècniques SHAP per identificar els factors que més contribueixen a les prediccions.

- **Conclusions, recomanacions i línies de treballs futures.**

El capítol 4 presenta les conclusions principals del treball, destacant la bona capacitat explicativa global del model (R^2 superior a 0,9 en tots els casos), les limitacions detectades en nivells baixos d'agregació a causa de possibles biaixos, així com recomanacions operatives i línies de treball futures orientades a millorar la precisió mitjançant anàlisis específiques i dades de projecció aportades per l'organització.

2. Disseny i desenvolupament de la solució

Aquest apartat consisteix en el conjunt de notebooks i scripts que s'han programat en llenguatge de programació Python, tant per obtenir documents intermedis, com informes i models a utilitzar.

Tots els notebooks i scripts tenen a l'inici fragments de codi per capturar les rutes relatives perquè els scripts o notebooks no tinguin problemes d'execució.

Els notebooks en alguns casos poden contenir fragments de codi (generació de mapes, resultats parcials), que no estan inclosos en els scripts perquè sols estan presents per realitzar validacions del progrés del producte, però que no aporten realment res al producte final.

El procés es realitzarà en 4 fases:

- Recollida de dades i desplegament de tot l'entorn.
- Preparació de les dades
- Modelització, avaluació i predictor
- La darrera fase, és una fase addicional, on es prepara una interfície textual per poder des d'ella executar tot el programari per obtenir els resultats.

2.1. Recollida de dades




Figura 2-1 Recollida de les dades necessàries en paral·lel

És la primera fase de la solució, es recullen els 6 arxius (taules) necessàries per poder realitzar el desenvolupament.

2.1.1. Projecció de la població

La finalitat d'aquest arxiu és poder utilitzar la població per fer realitzar les prediccions.

- Tipus de projecció: **Població projectada per comarques a 1 de gener per sexe i edat quinquennal. Escenari mitjà (base 2024)**
- Període de les dades: 2024 – 2049
- Origen de les dades: **Institut d'Estadística de Catalunya. Idescat** (dades públiques).

- Enllaç de la pàgina: <https://www.idescat.cat/dades/obertes/proj>
- Enllaç directe del recurs: <https://www.idescat.cat/pub/?id=proj&n=20961&by=com&f=zip&fi=ssv>
- Nom del fitxer: **proj20957com.zip** (conté un .csv amb el mateix nom).
- Observacions: Quan Idescat actualitza les projeccions, les que hi havia fins ara, s'arxiven en un altra apartat.

2.1.2. Àrees Bàsiques de Salut (ABS)

Aquest arxiu **es descarrega per 2 motius principals**, a banda del seu codi i nom oficial: **Obtenir la relació jeràrquica** de les ABS i les granularitats superiors, i en segon terme, **obtenir les dades de georeferència**.

- Període de les dades: Captura a l'estat de la descàrrega.
- Data de darrera recollida: 18/08/2025
- Origen de les dades: Dades Obertes de Catalunya. Transparència. Font: Catàleg Tècnic de dades del Departament de Salut.
- Enllaç de la pàgina: https://analisi.transparenciacatalunya.cat/Salut/-rees-b-siques-de-salut/tqzv-uu8e/about_data (clicar 'Exportar')
- Nom del fitxer: **Àrees_bàsiques_de_salut_20250818.csv**
- **Observacions:** La part numèrica del nom del fitxer depèn del dia de la descàrrega, es genera automàticament.

2.1.3. Límits administratius comarcals de Catalunya

La finalitat més important d'obtenir aquest fitxer és, igual que amb les ABS, tenir les geometries de les comarques per poder-les relacionar amb les geometries de les ABS.

- Període de les dades: Captura a l'estat de la descàrrega.
- Data de darrera recollida: 26/08/2025
- Origen de les dades: Dades Obertes de Catalunya. Transparència. Font: Institut Cartogràfic i Geològic de Catalunya (ICGC).
- Enllaç de la pàgina: https://analisi.transparenciacatalunya.cat/Urbanisme-infraestructures/L-mits-administratius-comarcals-de-Catalunya/aasi-gwnd/about_data (clicar 'Exportar')
- Nom del fitxer: **Límits_administratius_comarcals_de_Catalunya_20250826.csv**
- Observacions: La part numèrica del nom del fitxer depèn del dia de la descàrrega, es genera automàticament.

2.1.4. Taula de relació entre ABS, AGA, Sector sanitari i Regió sanitària

Aquesta taula no havia estat considerada en un principi, però la institució va estimar que seria interessant tenir en compte l'agregació d'AGA en el moment d'avaluar territorialment la càrrega d'altres hospitalàries.

- Període de les dades: Captura a l'estat de la descàrrega.
- Data de darrera recollida: 21/10/2025*

- Origen de les dades: CatSalut. Servei Català de la Salut (recollida interna)
- Nom del fitxer: **RCA_pob_x_abs_aga_ss_rs.xlsx**
- **Observacions:** Es presenta el fitxer amb les darreres dades descarregades, encara que ja es tenia una versió, s'ha considerat interessant utilitzar una font més actual (petits canvis en la consulta realitzada). automàticament.

2.1.5. Recollida de la població per àrea bàsica de salut. Registre central de població del CatSalut

Aquestes són les dades de població que serviran per entrenar la modelització de les dades, seran les característiques (*features*), juntament amb les coordenades (centroids) de les ABS respectives. Recullen el període 01/01/2018 fins el 31/12/2024

- Període de les dades: Tall a 31/12/2024 (població oficial 01/01/2025)
- Data de darrera recollida: 21/10/2025*
- Origen de les dades: CatSalut. Servei Català de la Salut (recollida interna)
- Nom del fitxer: **RCA_ABS_sexe_i_g5_SOLS_CODIS_18_25.xlsx**
- **Observacions:** Mateix procés que l'anterior. També es descarrega paral·lelament un fitxer anomenat RCA_ABS_sexe_i_g5_SOLS_CODIS_18_25EAP.xlsx per si es vol fer alguna variació final en l'anàlisi de les dades. Un altra fitxer descarregat per tenir com a referència (però sobre el qual no es fa manipulació) és un anomenat RCA_ABS_sexe_i_g5_ETIQUETES.xlsx
- **Informació addicional:** Aquestes dades també es poden recollir des del portal de Dades Obertes, encara que es necessitin realitzar manipulacions addicionals per obtenir els mateixos resultats
- https://analisi.transparenciacatalunya.cat/Salut/Registre-central-de-poblaci-del-CatSalut-poblaci-p/ftq4-h9vk/about_data automàticament.

2.1.6. Recollida del nombre d'ingressos hospitalaris catalogats segons tipus d'alta (mèdica, quirúrgica i obstètrica).

Igual que les dades anteriors, aquestes són les variables objectiu (*targets*), per poder entrenar i avaluar l'eina predictiva que es genera, esta agregades de mateixa manera, anualment i per ABS.

- Període de les dades: 01/01/2018 al 31/12/2024
 - Data de darrera recollida: 08/10/2025
 - Origen de les dades: CatSalut. Servei Català de la Salut (recollida interna)
 - Nom del fitxer: **CMB Altes_ABS_SCS_BASE_anual.xlsx**
- Observacions:** Sols es tenen en compte els ingressos provinents del Registre Central d'Assegurats del CatSalut.

2.2. Preparació de l'entorn de treball

A partir d'un directori en un lloc qualsevol determinat es realitza el següent procés.

2.2.1. Creació d'un entorn virtual de Python

Aquest pas, podria ser opcional, però aïlla el producte de la instal·lació de Python de la màquina que l'allotja, podent instal·lar els paquets necessaris sense conflictes de dependències ni malmetre la instal·lació actual.

- Versió de Python instal·lada: 3.12.9
- Carpeta de l'entorn: **.venv** (Generada amb l'editor de programació, Visual Studio Code).
- Amb la solució s'adjunta un arxiu de nom **requeriments_DEF.md** amb les ordres per instal·lar els paquets necessaris, tant en mode *dry-run* (per saber si pot haver algun conflicte) com en mode real, per exemple:

```
pip install -U --dry-run xgboost lightgbm
pip install -U xgboost lightgbm
```
- S'ha de tenir en compte que no s'especifiquen versions, per poder donar flexibilitat a una instal·lació en qualsevol entorn.

2.2.2. Desplegament d'arxius de la solució i creació de carpetes

Un dels productes entregats és una carpeta que s'ha de copiar en el directori de l'entorn de treball.

- A la carpeta principal de l'entorn de treball s'allotjaran els scripts, notebooks generats, fitxers d'estil i de paquets requerits.
- Es desplega una carpeta anomenada '**dades**' on s'allotgen en subcarpetes els 6 arxius que hem obtingut per poder efectuar el procés. Detallem l'estructura:




Figura 2-2 Estructura inicial al desplegar les carpetes i els arxius

De totes maneres, a la solució ja s'inclouen els mateixos arxius amb els noms netejats, però és part del procés que posteriorment es realitza en la depuració de les dades (es reanomenen els arxius per poder-los treballar sempre amb el mateix nom). L'estat definitiu serà:




Figura 2-3 Estructura final al realitzar-se el preprocés de dades

- A banda d'aquestes carpetes dins de la carpeta 'dades' també hi ha una carpeta anomenada '**descripcions**' amb el contingut de text requerit per la interfície textual.
- Finalment, s'aporta una carpeta anomenada '**treball**' que contindrà tots els arxius generats pels notebooks o scripts, com poden ser totes les taules, informes, i dades dels models. Aquesta carpeta està inclosa, però es genera totalment quan s'executen els scripts de la solució o producte.

2.3. Neteja i preparació de dades

Un cop instal·lats els scripts a la carpeta base i els 6 arxius de dades a les subcarpetes corresponents, es pot iniciar la preparació de cadascun dels arxius. Es normalitzaran els noms dels arxius a les subcarpetes si cal i posteriorment s'utilitzaran per generar les taules necessàries.

Per realitzar aquesta tasca hem d'executar per ordre els següents scripts (tots els scripts tenen la seva versió notebook que són on originalment es van realitzar les tasques de proves reiterades).

Els notebooks en alguns casos poden contenir fragments de codi (generació de mapes, resultats parcials), que no estan inclosos en els scripts perquè sols estan presents per realitzar validacions del progrés del producte, però que no aporten realment res al producte final.




Figura 2-4 Neteja i preparació de les dades de manera consecutiva

2.3.1. Processar projeccions de població

Aquest pas és el que utilitzant el fitxer desat a la carpeta **dades/població** i realitza les següents accions:

- Nom del script: **etl_poblacio.py**
- Nom del notebook d'origen: **recull_poblacioCom_03.ipynb**
- Canvia el nom de l'arxiu a **proj.csv**
- Comprova quines columnes té, per quedar-se amb les columnes any(Numèrica), comarca o Aran(String), edat(Numèrica), sexe(String), valor(Numèrica).
- Agrega les edats quinquennals, agrupant les que excedeixen de 94 en la categoria "95 o més".
- Crea 3 columnes noves, que són el valor de l'any anterior [valor_anterior], la diferència resultant [diferencia], i el percentatge que comporta [rati_variatio].
- Es neteja els registres amb columnes nul·les [NaN].
- El resultat d'aquesta taula es gravarà en arxius tipus .csv i .xlsx amb el nom **comarspob**.
- Es fa una agregació de la mateixa taula agrupant totes les comarques en una anomenada "Catalunya" i el resultat es gravarà en 2 arxius tipus .csv i .xlsx amb el nom **comcatpob** (dades de l'agregació Catalunya, per any, sexe i edat quinquennal, sols per tenir per consulta / referència).
- Posteriorment es categoritzen (les dades de comarspob) amb codis numèrics el sexe (0,1) [Sexe_Codi] i les edats quinquennals (1-20) [Edat_Codi].
- La taula obtinguda es pivota tal que queda una fila per any i per comarca i 20 grups d'edat per cada sexe. Total 42 variables.
- El resultat d'aquesta taula pivotada es gravarà en l'arxiu **comarspob_pivot**, tant en els seus formats .csv com .xlsx.
- Es crea la subcarpeta **dades/treball** (si no existeix) i es graven els 6 arxius que hem preparat.

2.3.2. Mapeig territorial de les ABS

En aquest pas es recullen els fitxers de la subcarpeta **dades/territoris** i es realitzen les següents accions:

- Nom del script: **mapeig_territorial.py**
- Nom del notebook d'origen: **recull_territoriss_09.ipynb**
- Es canvia els noms dels arxius a **Àrees_bàsiques_de_salut.csv** i **Límits_administratius_comarcals_de_Catalunya.csv** respectivament.
- A cadascuna de les taules, esborrem els registres que no tenen geometria i la resta els convertim a una projecció amb la que es pugui treballar millor sobre pla.

- Afegim els centroides (coordenades x e y) a ambdues taules.
- Preparem una funció per graficar tant les ABS com les comarques, per comprovar que hem realitzat correctament a l'espai els polígons.
- S'obté en una taula nova la relació de proporció de cada comarca que pertany a cada ABS, mitjançant la intersecció, es guarden les proporcions en una variable tipus diccionari anomenada [Camp] a la taula d'ABS.
- Es graven a la carpeta **dades/treball** dos arxius amb formats .csv i .xlsx amb el nom **abss_ref**.

2.3.3. Mapeig de les AGA (Àrees de Gestió Assistencial) amb les ABS

Al ser una petició de la institució posterior a l'inici de l'anàlisi de les dades a treballar, i a l'arxiu Àrees_bàsiques_de_salut.csv, obtingut de Dades Obertes, no existia aquesta correlació, es va haver d'obtenir de manera interna un arxiu que relacionés les AGA amb les ABS per afegir-les al mapeig fet en el punt anterior.

- Nom del script: **mapeig_agas.py**
- Nom del notebook d'origen: **recull_agas_03.ipynb**
- Es canvia el nom de l'arxiu de **dades/rca** perquè quedi amb el nom **RCA_pob_x_abs_aga_ss_rs.xlsx**.
- S'esborra la columna de població i les files duplicades.
- Posteriorment esborrem les files que tenen com a codi en qualsevol camp o "SES" o "ALT", que signifiquen que poden ser AGA o ABS desconegudes.
- Es recupera la taula generada en el punt anterior **abss_ref** i se li assigna l'AGA relacionada (es comprova que no sigui una re execució del script per no duplicar la columna).
- Es graven a la subcarpeta **dades/treball** els arxius tant en format .csv com .xlsx tant de les AGA depurades amb el nom **AGAs** i es torna a gravar de nou l'arxiu **abss_ref** amb l'AGA afegida.

2.3.4. Depuració de la població RCA (Registre Central d'Assegurats)

En aquest pas es combina la població assegurada CatSalut pel tall anual amb les ABS que hem ja hem obtingut.

- Nom del script: **etl_rca.py**
- Nom del notebook d'origen: **recull_rca_pob_04.ipynb**
- Es canvia el nom de l'arxiu de **dades/rca** perquè quedi amb el nom **RCA_ABS_sexe_i_g5_SOLS_CODIS.xlsx**.
- Agreguem les files perquè sols hi hagi un codi ABS per any.
- Pivotem les variables perquè tinguem per any i ABS els 20 grups d'edat per cada sexe.
- Es carrega el fitxer **abss_ref.csv** i assignem mitjançant t el codi de l'ABS, les variables [Camp, centroid_x, centroid_y].
- Esborrem els registres on hi hagi algun valor nul (no s'hagi pogut establir la relació, al ser ABS noves i que no estiguin al fitxer de Dades Obertes, per exemple).
- Es grava a la subcarpeta **dades/treball** la taula resultant amb els formats .csv i .xlsx amb el nom **rca_abss**.

2.3.5. Processament i mapeig d'altres anuals per ABS

El següent pas consisteix en afegir a la taula – arxiu obtingut anteriorment, les altes mèdiques, quirúrgiques i obstètriques. **La taula resultant serà amb la que es faci tot el procés de modelització del producte**, en altres paraules, serà el conjunt de dades d'entrenament i validació.

- Nom del script: **mapeig_rca_altes.py**
- Nom del notebook d'origen: **recull_altes_05.ipynb**
- Es canvia el nom de l'arxiu de **dades/salut** perquè quedi amb el nom **CMB Altes_ABS_SCS_BASE_anual.xlsx**.
- Es carrega la taula a partir del fitxer Excel anterior, unint si escau els fulls de treball que hi hagi (aquesta part esdevé de que inicialment s'obtenia un fitxer d'altres diàries).
- Ens quedem amb els camps ["Any de l'ingrés", "Mèdica", "Quirúrgica", "Obstètrica", "ABS EAP codi", "ABS EAP nom"] i agreguem (per si de cas) les altes de manera anual.
- Recuperem el fitxer **abss_ref.csv**, per poder associar les ABS amb els seus centroides.
- Arribat aquest punt, si del darrer any que hi ha tall de població oficial encara no tenim les altes, es genera una taula apart que es gravarà a la carpeta **dades/treball** amb el nom **predir_RCA_{any}** (on any és un número de 4 dígits que correspon a l'any a projectar), per poder fer prediccions amb els models que es generin.
- La resta de dades (amb anys amb altes i sense nuls) es gravarà amb els nom **abs_gravable**, també es desarà un arxiu de sols 100 registres amb el nom **abs_gravable100**.
- Es graven a la subcarpeta **dades/treball**, en els formats .csv i .xlsx els fitxers **abs_gravable** i **abs_gravable100**, i si és possible també el fitxer **predir_RCA_{any}**.

2.3.6. Generació de projeccions de població per ABS

Per tenir dades per poder fer les prediccions, necessitem les projeccions de població futura que poden tenir les ABS amb les que hem estat treballant. A tal efecte, fem servir els arxius generats anteriorment **abs_gravable.csv**, **comarspob_pivot.csv** i **abss_ref.csv** per calcular unes projeccions de població proporcionals.

- Nom del script: **calcular_carrega.py**
- Nom del notebook d'origen: **recull_proj_pob_05.ipynb**
- Es carreguen les taules contingudes en els 3 arxius esmentats anteriorment (**abs_gravable.csv**, **comarspob_pivot.csv** i **abss_ref.csv**).
- Es crea una funció per remapejar les etiquetes dels camps.
- Es crea una funció per calcular la població que li correspon a cada ABS a partir de la comarca. Es fa servir dins de la funció / procediment següent.
- Es crea una funció per obtenir les projeccions de tots els anys i ABS.

- Generem les projeccions, en principi pot ser de tot el conjunt sencer de les projeccions de població comarcal, però ho he retallat a com a màxim 5 anys, per considerar que potser pot haver un biaix gran en valors superiors.
- Es graven a la subcarpeta **dades/treball** els arxius en format .csv i .xlsx de la taula de projeccions obtinguda amb el nom **predir_proj_{pred_any_min}** i **predir_proj_{pred_any_max}** on pred_any_min i pred_any_max són l'any en format de 4 dígits mínim i màxim respectivament, per exemple *predir_proj_2025_2029.csv*.

2.4. Modelització i eina d'inferència (predictor)

Aquesta és possiblement la fase principal de tot el desenvolupament, ja que és la que en realitat porta la càrrega principal del producte i solució final.




Figura 2-5 Procés per a la selecció de models d'aprenentatge automàtic

2.4.1. Consideracions prèvies

Les dades que es faran servir per obtenir els models han estat originades a partir de tots els processos anteriors, però poden suplir-se directament per l'organització comportant l'estructura de la taula continguda en **abs_gravable**: 46 variables totes numèriques amb la següent estructura:

- 1 camp amb el valor anual [any].

- 40 camps de la població per edats quinquennals (1 = 0-4, 2 = 5-9, ... 20 = 95 o més) per sexe (0 = home, 1= dona) en el format [1_0, 1_1, ..., 20_1].
- 2 camps que refereixen el centroide geogràfic de l'ABS [centroid_x, centroid_y].
- Els camps de cada tipus d'alta [Mèdica, Quirúrgica, Obstètrica].

Per altra banda, inicialment es valorava utilitzar un sols model, però es va determinar més positiu avaluar individualment les dades per obtenir cada tipus d'alta (cada 'target').

S'avaluen 5 models per obtenir els resultats, 4 d'ells basats en boosting (**Random Forest, Gradient Boosting, XGBoost i LightGBM**) i per comparar el benefici de rendiment qualitatiu també la **Regressió Lineal**.

Per triar els millors hiperparàmetres a utilitzar per cada model per avaluar cada tipus d'alta, s'ha aplicat un procediment d'optimització predefinida dins d'un espai de cerca concret, avaluats mitjançant validació creuada.

Finalment s'escull el millor model a aplicar per obtenir cada tipus d'alta a partir d'un score determinat entre diverses mètriques, ja que si apliquem una sola mètrica detectem un comportament del model però perdem uns altres. Per aquest motiu:

- **MAE** (Error Absolut Mitjà): Ens serveix per trobar el valor de desviament mitjà però perd de vista els *outliers* (valors extrems atípics).

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **RMSE** (Arrel de l'Error Quadràtic Mitjà): Ens serveix per detectar que hi ha errors atípics (outliers o grans), però perd la vista la consistència mitjana.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- **R²** (Coeficient de Determinació): Ens serveix per identificar si el model captura la variabilitat de les dades, però perd de vista les dues anteriors. En altres paraules, ens diu quant de bo és el model però no els problemes que té.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- **SMAPE** (Error Percentual Absolut Mitjà Simètric), s'escull per avaluar mètriques d'un sol valor, com quan avaluem l'agregació a nivell d'ABS, on per exemple, el coeficient de determinació, no es pot calcular. No es comuna fer-

la servir (es millor per temperatures o valors sinusoidals), però en aquest cas ens serveix de referència. El seu rang és de 0 a 200.

$$SMAPE = 100 \times \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2}$$

El *score* final per cada model es pondera de la següent manera: es normalitzen totes les mètriques perquè els seus valors siguin entre 0 i 1 (0 pitjor, 1 millor) i apliquem la següent ponderació:

$$score = MAE \times 30\% + RMSE \times 30\% + R^2 \times 25\% + SMAPE \times 15\%$$

El pes recau sobre MAE i RMSE, i el SMAPE (la considerem molt poc) sols ens dona suport.

2.4.2. Procés de modelització (elecció i entrenament de models)

En aquest procés mitjançant el script / notebook es generen dos fitxers amb les dades utilitzades per entrenar els models i els models escollits amb els millors hiperparàmetres, un fitxer amb l'anàlisi dels models i un informe dels resultats obtinguts.

És la peça que més temps ha trigat en desenvolupar-se i de la qual més versions s'han realitzat, inclòs fent un canvi de paradigma sobre la idea base i 11 versions diferents de la darrera estructura.

- Nom del script: **modelitzar.py**
- Nom del notebook d'origen: **recull_models_NEXT_GENERATION_11.ipynb**
- La forma d'executar aquest script és directament o bé amb el paràmetre (-b, -basic) per fer una tria de models sense fer un anàlisi en profunditat (20 vegades mínim més curt).
- Comença per carregar els mòduls necessaris i preparar les variables inicials i globals.
- Es prepara un algoritme per calcular la mètrica **SMAPE**, ja que no es troba implementat a SciKit-Learn.
- En una primera fase, es comprova que hi son les dades per poder entrenar, i es preparen els paquets d'entrenament i test (reservant un any de dades per la realització i comprovació de resultats).
 - En una segona fase hi ha vàries sub-fases.
 - Es separen les característiques i els objectius.
 - Es preparen 5 models diferents i varis paquets d'hiperparàmetres.
 - Si s'escull un entrenament bàsic es fan valoracions mínimes.
 - Si no, s'avalua per quins hiperparàmetres són millor per model.
 - S'entrenen els models i es calculen les mètriques (**MAE**, **RSME**, **R2**, **SMAPE**).

- Per cada model, es ponderen les mètriques per tipus d'alta. Es selecciona el model amb la puntuació més alta per tipus d'alta.
- Es graven en .xlsx i .csv un fitxer amb les mètriques i ponderacions anomenat '**anàlisis_models**'. Igual que la resta d'arxius següents, es graven, com tota la resta, a la carpeta **dades/treball**.
- Es bolquen els models escollits en un arxiu (tipus 'Pickle') anomenat '**models_seleccionats.pkl**', per en la següent fase generar la predicció d'altres.
- També es bolquen les dades d'entrenament i test anomenat '**dadesModel.pkl**' per poder fer reentrenaments i anàlisis posteriors.
- Finalment **es prepara un informe exhaustiu en format de llibre de treball Excel**, que conté:
 - Un full resum amb la data de generació, temps transcorregut per entrenar els models, quins són els models utilitzats, quines són les mètriques que es calculen, quin és el model que s'ha fet servir per tipus d'alta (model òptim), i els resultats globals per tipus d'alta.
 - Un segon full recull el resultat desagregat per regions sanitàries i avaluat també amb les quatre mètriques fetes servir.
 - Tres fulls més desagregats en sectors sanitaris, AGAs i ABSs, on con són sobre dades parcials que poden arribar a ser d'un sols registre, sols es calcula la mètrica SMAPE.

Informe del model predictiu optimitzat i resultats obtinguts			
Data de la generació:	28/11/2025		
Temps empleat per l'anàlisi:	32 minuts i 0.08 segons		
Models avaluats:	Linear Regression, Random Forest, Gradient Boosting, XGBoost, LightGBM Cadascun amb hiperparàmetres optimitzats		
Àrees Bàsiques de Salut avaluades:	376 Pot variar del nombre real, en funció del creuament de les dades		
Mètriques utilitzades per avaluar els resultats			
MAE	Error Absolut Mitjà (Mean Absolute Error)		
RMSE	Arrel de l'Error Quadràtic Mitjà (Root Mean Squared Error)		
R2	Coeficient de Determinació (Coefficient of Determination)		
SMAPE	Error Percentual Absolut Mitjà Simètric (Symmetric Mean Absolute Percentage Error) 0-200%		
Resultats totals per tipus d'alta			
	Típus	Altes	Predicció
	Mèdica	385201	384897,6
	Quirúrgica	475052	466198,6
	Obstètrica	45064	43860,18
			Error
			-303,4
			-8853,4
			-1203,82
Model òptim aplicat per tipus d'alta			
	Alta	Model	Paràmetres
	Mèdica	XGBoost	learning_rate=0.1, max_depth=5, ...

2.4.3. Realitzar la predicció (inferència) de les dades

Amb el següent script es calculen les prediccions d'altres a partir dels dos arxius de dades (.pkl) bolcats anteriorment a la carpeta **dades/treball**. **Aquest és l'únic script realment necessari** (a banda que es tinguin de preprocessar si calen les dades a predir), per dur la tasca predictiva (els models ja estan entrenats i obtinguts els millors).

- Nom del script: **fer_prediccio.py**
- Nom del notebook d'origen: **recull_prediccio_mqo_02.ipynb**
- Aquest script té varies opcions per executar-se:
- Per una banda, s'ha d'afegir amb el paràmetre (-p, --predir) amb el nom d'un fitxer de la carpeta de treball que comenci per "predir" (obtinguts en la preparació de dades, com '**predir_proj_2025_2029.csv**').
- Les altres opcions, són executar-lo directament, fent un *Rolling-training* del models (paràmetre -r, --rolling), que es fer servir també les dades de proves per re entrenar el model de nou per predir les dades, o entrenar de nou el models que tenim (-e, --entrena), amb dades diferents de les inicials, que ja estan a la carpeta de treball preprocessades.
 - Comença el script carregant llibreries i generant variables globals.
 - Posteriorment es preparen varies funcions per carregar els diferents tipus de dades que es necessiten per dur a terme la tasca.
 - La següent fase ja és fer la inferència de les dades i obtenir la predicció sobre les dades facilitades.
 - Es desa en formats **.csv** i **.xlsx** el fitxer '**prediccio_{any}_{any}**' on '*{any}*' són els anys inicial i final dels que s'ha fet la predicció.

2.4.4. 'Frontend' per executar els scripts

El tutor del TFG (Alfons Marquès I Cancio) va fer el suggeriment de que seria molt positiu pel projecte que aquesta bateria de scripts pogués estar executada mitjançant una interfície visual, sobretot si l'eina havia de ser desplegada. He recollit la seva indicació i he generat, un TUI (Text User Interface) amb l'ajut de la llibreria de Python **Textual**, concentrant-me més en l'aspecte de que fos reproduïble des de qualsevol tipus de consola sense necessitat d'un entorn gràfic. Aquest frontend seria l'únic script a executar i fins i tot es podria cridar des de un accés directe.

- No sols aporta un accés per a consola de manera lleugera sinó que fins i tot en les distribucions de sistemes més minimalistes es podria veure gràficament.
- A més, la seva disposició en 2 panells, ofereix molta més informació del que fa l'eina i si es compleixen els requisits per poder fer-la servir. També aporta que els paràmetres son facilitats per la consola.

- Com a control de monitoratge té un tercer panell que és la sortida d'informació tant del estat del procés amb marca d'hora com de poder interrompre en qualsevol moment el procés.
- Es podria accedir **remotament** a través de consoles que acceptessin interaccions en qualsevol part de la pantalla, que poden ser la majoria de **sistemes tty**.




Figura 2-6 Accés directe des de consola

- De totes maneres, l'eina també pot ser executada com servidor i poder ser accessible des de qualsevol navegador i mitjançant internet (parametritzant les adreces i ports necessaris).





Figura 2-7 Frontend en un navegador implantat en una màquina MX Linux

Breu descripció del script

- Nom del script: **taulell_control.py**
- Es carreguen les llibreries
- Es preparen variables d'accés als scripts que s'hauran de cridar.
- Es creen funcions per detectar quin tipus de fitxers poden ser requerits.
- Es prepara la funció per llegir de la subcarpeta dades/definicions la informació necessària perquè l'usuari conegui què fa cada script i què necessita per poder-se executar.
- Es creen les classes (Widget) necessàries per poder tant realitzar l'execució dels scripts com per visualitzar en les finestres necessàries les interaccions possibles (passos, definicions, diàlegs d'execució i panell de sortida de missatges i temps de realització de les tasques).
- Finalment es crea la classe principal (App), amb totes les definicions i variables de caràcter general, que es cridarà si és executada com a script principal i no com a mòdul.
- L'ordre necessària per executar el script (o aplicació Textual) pot se qualsevol d'aquestes dos (sempre que l'entorn de Python estigui configurat /activat i suposant que estem a la carpeta base del producte, si no, hauríem de canviar les rutes als directoris):
 - **python taulell_control.py**
 - **textual run taulell_control.py**
- Si es volgués servir a un navegador web (en mode local) senzillament hauríem de fer la crida, i tindriem l'adreça per defecte:
 - **textual serve taulell_control.py**



```
$ textual serve taulell_control.py
TEXTUAL-SERVE v1.1.3
Serving 'python taulell_control.py' on http://localhost:8000
Press Ctrl+C to quit
```

Figura: Llançament del servidor de textual en mode local

- Si volguéssim llençar el servidor per a qualsevol màquina accessible des de la xarxa, sols caldria llençar-lo en mode "Broadcast" (difusió) i declarar quina seria la URL pública d'accés. Addicionalment, es poden configurar més paràmetres si cal. Per exemple
 - **Textual serve -host 0.0.0.0 -url <http://192.168.100.196:8000> taulell_control.py**

2.4.5. Productes generats i obtinguts

Amb la memòria s'acompanya una carpeta anomenada scripts i dades amb el contingut necessari per obtenir els fitxers generats i els fitxers generats pròpiament. A les subcarpetes es recullen alguns elements addicionals, que no els anomenarem aquí al considerar-se complementaris.

Contingut de la carpeta base

- Es recull el programari realitzat
- Un arxiu en format Markdown on presento l'ordre per provar d'instal·lar els paquets necessaris, i l'ordre per instal·lar-los si tot és correcta (manera segura de comprovar si la instal·lació de paquets pot malmetre llibreries ja existents en l'entorn de destí).

instal·lació de paquets necessaris
requeriments_DEF.md

- Posteriorment estan els scripts que es necessiten i el seu equivalent (o font original) en format notebook (.ipynb), adjunto la darrera versió dels notebooks utilitzats (en ordre del seu ús).

Nom script	Nom notebook font
etl_poblacio.py	recull_poblacioCom_03.ipynb
mapeig_territorial.py	recull_territoriss_09.ipynb
mapeig_agas.py	recull_agas_03.ipynb
etl_rca.py	recull_rca_pob_04.ipynb
mapeig_rca_altes.py	recull_altes_05.ipynb
calcular_carrega.py	recull_proj_pob_05.ipynb
modelitzar.py	recull_models_NEXT_GENERATION_11.ipynb
fer_prediccio.py	recull_prediccio_mqo_02.ipynb

- Els darrers arxius de la carpeta són els que serveixen per executar el '*frontend*' TUI programat amb la llibreria Textual.

Frontend	
taulell_control.py	(només script)
estils.tcss	Estils necessaris

Contingut de la subcarpeta 'dades'

En aquesta carpeta tenim les subcarpetes amb els arxius necessaris per fer funcionar la solució com els productes obtinguts.

Nom	Carpeta a dades
proj.csv	poblacio
RCA_ABS_sexe_i_g5_SOLS_CODIS.xlsx	rca
RCA_pob_x_abs_aga_ss_rs.xlsx	rca
CMB Altes_ABS_SCS_BASE_anual.xlsx	salut
Límits_administratius_comarcals_de_Catalunya.csv	Territoris
Àrees_bàsiques_de_salut.csv	Territoris

Contingut de la subcarpeta 'dades/treball' – contingut generat

Nom	Format
abss_ref.csv	csv (text), xlsx (excel)
abs_gravable.csv	csv (text), xlsx (excel)
abs_gravable100.csv	csv (text)
AGAs.csv	csv (text), xlsx (excel)
analisi_models.csv	csv (text), xlsx (excel)
comarspob.csv	csv (text), xlsx (excel)
comarspob_pivot.csv	csv (text), xlsx (excel)
comcatpob.csv	csv (text), xlsx (excel)
dadesModel	pkl (pickle, joblib)
informe_analisi_modelitzacio_20251128.xlsx	xlsx (excel)
models_seleccionats.pkl	pkl (pickle, joblib)
prediccio_2025_2025.csv	csv (text), xlsx (excel)
prediccio_2025_2025ROLLING *	csv (text), xlsx (excel)
prediccio_2025_2029.csv	csv (text), xlsx (excel)
predir_proj_2025_2029.csv	csv (text), xlsx (excel)
predir_RCA_2025.csv	csv (text), xlsx (excel)
rca_abss.csv	csv (text), xlsx (excel)

3. Resultats i validació dels models

A partir de l'informe generat i d'un anàlisi interpretatiu de les dades, intentarem donar cos al que hem obtingut com a models predictors, que de totes les solucions / productes obtinguts, són els que realment aporten significat a l'estudi realitzat i finalitat d'aquesta memòria.

3.1. Conclusions de l'informe i mètriques

Hem de remarcar que s'ha treballat en sols 6 episodis d'entrenament (6 anys, 2018 - 2023) i 1 de per validar (any 2024). També que encara que entrem en analitzar diferents nivells d'agregació, l'avaluació principal és de si el model funciona bé a nivell global, ja que en cap cas volíem un fals biaix de sobre-estimació. Per aquest motiu sempre es natural que quan disminuïm el nivell d'agregació i augmentem la granularitat, trobem biaixos més grans.

També destacar que no es treballa amb el total de les dades recollides degut que al mapejar els registres, hi ha dels que no s'han pogut trobar centroides degut a la desaparició o creació tant d'ABS com de comarques, ja que des de dades obertes sempre s'ha treballat amb la darrera informació pública actualitzada.

Per tant, cal remarcar que l'**objectiu principal** del model no és la predicció exacta de cada valor individual, sinó **la correcta estimació de la distribució global de la càrrega assistencial** que posteriorment permeti orientar la compra d'altres dins la xarxa hospitalària, en coherència amb la distribució territorial de la població associada a les Àrees Bàsiques de Salut (ABS).

3.1.1. Resultats globals

Per avaluar el rendiment global del sistema predictiu desenvolupat, s'han analitzat els resultats obtinguts a nivell agregat per a les diferents tipologies d'alta hospitalària (mèdica, quirúrgica i obstètrica). L'avaluació s'ha realitzat sobre un conjunt de 376 Àrees Bàsiques de Salut, nombre que pot variar lleugerament en funció del creuament i disponibilitat de les dades.

S'han considerat diversos models predictius, incloent regressió lineal i diferents tècniques basades en agrupaments i boosting (Random Forest, Gradient Boosting, XGBoost i LightGBM), tots ells amb una selecció sistemàtica dels hiperparàmetres per maximitzar el rendiment predictiu.

Les mètriques utilitzades han estat el MAE, RMSE, coeficient de determinació (R^2) i l'SMAPE, amb l'objectiu d'obtenir una visió completa tant de l'error absolut com relatiu.

Tipus	Altes	Predicció	Error	MAE	RMSE	R2	SMAPE
Mèdica	385201	384897,6	-303,4	78,92	109,44	0,95	8,35
Quirúrgica	475052	466198,6	-8853,4	94,46	130,87	0,95	7,89
Obstètrica	45064	43860,18	-1203,82	12,98	17,2	0,93	12,01

Els resultats globals mostren un rendiment elevat del model, amb valors de R^2 superiors a 0,95 per a les altes mèdiques i quirúrgiques, i de 0,93 per a les obstètriques. A nivell agregat, les prediccions presenten una lleugera infraestimació en tots tres casos, especialment en les altes quirúrgiques, tot i que els errors absoluts i percentuals es mantenen dins de marges reduïts.

Pel que fa al model òptim seleccionat, les tècniques basades en boosting han estat les que han proporcionat els millors resultats. En concret, XGBoost ha estat el model amb millor rendiment per a les altes mèdiques i obstètriques, mentre que el Gradient Boosting ha resultat més adequat per a les altes quirúrgiques. Aquesta diferenciació reforça la necessitat de tractar cada tipologia d'alta com un problema predictiu amb dinàmiques pròpies.

Considerar que l'error a les altes obstètriques (1203 sobre 45064) és sensiblement superior a el de els altres errors molt possiblement a que els ingressos per aquest tipus són força inferiors a la resta, representant sols el 5% dels ingressos.

Cal destacar que aquests resultats corresponen a una anàlisi global agregada. En apartats posteriors s'analitza el comportament del model a diferents nivells de granularitat territorial.

3.1.2. Resultats a nivell de regió sanitària

Un cop validat el comportament del model a nivell global, s'ha realitzat una anàlisi a un segon nivell d'agregació corresponent a les regions sanitàries. Aquest nivell permet avaluar la capacitat del model per capturar diferències territorials rellevants en l'activitat hospitalària, mantenint una visió agregada útil per a la planificació estratègica, sobretot perquè en moltes ocasions la presa de decisions a nivell de regió sanitària, es fa de manera força independent.

Altes mèdiques

Nom regió sanitària	Codi	Mèdica	predicció	MAE	RMSE	R2	SMAPE
Alt Pirineu i Aran	71	3712	3571,17	25,05	35,05	0,98	8,64
Barcelona Ciutat	79	86490	84374,22	102,79	130,03	0,91	8,27
Barcelona Metropolitana Nord	76	100917	103134,34	98,25	137,01	0,89	9,51
Barcelona Metropolitana Sud	75	56349	56390,09	84,22	104,33	0,93	8,08
Camp de Tarragona	62	26210	25739,42	55,05	72,8	0,97	7,51

Catalunya Central	67	22229	21718,11	47,05	64,35	0,97	6,88
Girona	64	40047	40842,99	59,08	84,67	0,98	6,86
Lleida	61	17013	16476,3	53,02	70,95	0,97	10,21
Penedès	70	22782	23585,08	72,21	108,86	0,95	7,49
Terres de l'Ebre	63	9452	9065,89	83,58	103,79	0,91	9,89

Altes quirúrgiques

Nom regió sanitària	Codi	Quirúrgica	predicció	MAE	RMSE	R2	SMAPE
Alt Pirineu i Aran	71	5085	4727,43	86,8	109,58	0,91	13,91
Barcelona Ciutat	79	98654	94947,92	105,97	132,11	0,9	7,58
Barcelona Metropolitana Nord	76	133158	129234,81	104,97	139,13	0,95	7,63
Barcelona Metropolitana Sud	75	64493	66573,96	105,14	128,67	0,92	8,65
Camp de Tarragona	62	32688	30695,08	81,04	121,23	0,96	7,86
Catalunya Central	67	27512	27231,3	67,6	87,67	0,95	7,56
Girona	64	51316	51525,58	69,96	122,84	0,97	6,11
Lleida	61	21445	21583,41	66,38	85,87	0,97	8,58
Penedès	70	28775	28012,91	135,98	209,33	0,88	10,05
Terres de l'Ebre	63	11926	11666,21	68,9	90,96	0,97	5,77

Altes obstètriques

Nom regió sanitària	Codi	Obstètrica	predicció	MAE	RMSE	R2	SMAPE
Alt Pirineu i Aran	71	401	453,13	8,39	10,04	0,93	23,99
Barcelona Ciutat	79	8744	8412,47	14,45	19,47	0,82	11,11
Barcelona Metropolitana Nord	76	11013	10751,97	13,37	16,8	0,91	12,45
Barcelona Metropolitana Sud	75	6151	6093,91	13,39	16,89	0,91	10,62
Camp de Tarragona	62	3501	3442,13	10,87	15,13	0,94	9,77
Catalunya Central	67	2625	2491,96	8,3	11,81	0,96	10,05
Girona	64	5879	5727,91	14,91	19,16	0,97	12,32
Lleida	61	2736	2600,29	11,49	15,62	0,96	14,73
Penedès	70	2688	2678,83	12,96	16,84	0,92	12,94
Terres de l'Ebre	63	1326	1207,58	17,03	23,9	0,86	13,79

Els resultats mostren un rendiment globalment elevat en totes les regions sanitàries, amb valors del coeficient de determinació majoritàriament superiors a 0,9 en les tres tipologies d'alta. En particular, les altes mèdiques i quirúrgiques presenten un comportament molt estable entre regions, mentre que les altes obstètriques mostren una major variabilitat, fet atribuïble tant a un menor volum absolut com a una major sensibilitat a factors locals.

S'observen diferències entre regions amb grans volums assistencials, com Barcelona Ciutat o les regions metropolitanes, i regions amb poblacions més reduïdes, com Alt Pirineu i Aran. En aquestes darreres, tot i assolir valors elevats de R^2 , els errors percentuals poden ser més alts, especialment en l'àmbit obstètric, la qual cosa és coherent amb la naturalesa estadística de sèries amb menor nombre d'observacions.

Malgrat aquesta heterogeneïtat territorial, **el model manté una capacitat predictiva robusta en totes les regions analitzades**, amb errors absoluts i relatius continguts. Aquest fet reforça la seva idoneïtat com a eina de suport a la planificació sanitària a escala de regió sanitària, permetent anticipar càrregues assistencials amb un nivell de precisió adequat per a la presa de decisions en l'àmbit de la contractació.

Nota: el següents nivells d'agregació, degut a que alguns casos comprenen un nombre molt reduït d'observacions agregades, pel que **a partir d'aquí, s'ha optat per utilitzar exclusivament la mètrica SMAPE com a indicador de rendiment, evitant així possibles errors o interpretacions incorrectes associades a altres mètriques.**

3.1.3. Resultats a nivell de sector sanitari

Cal destacar que aquests resultats tenen un caràcter orientatiu. El model predictiu ha estat entrenat a partir d'un conjunt de dades limitat en el temps (sis anys d'entrenament i un any de validació), i amb un enfocament global destinat a capturar patrons generals de comportament assistencial, no dinàmiques específiques de cada sector sanitari.

El patró d'anàlisi serà el mateix en sectors, AGA i ABS

Pitjor SMAPE per tipus	Nom sector sanitari	Valor (%)
Mèdica	Barcelona Les Corts	19,53
Quirúrgica	Barcelona Les Corts	19,16
Obstètrica	Aran	32,61

Els valors de SMAPE obtinguts mostren, en la majoria dels sectors, errors percentuals continguts, especialment en les altes mèdiques i quirúrgiques, on habitualment se situen per sota del 10%. En canvi, les altes obstètriques presenten una major variabilitat, amb alguns sectors assolint valors més elevats,

fet atribuïble principalment a un menor volum absolut d'activitat i a una major sensibilitat de la mètrica en aquests contextos.

Els casos amb pitjor rendiment percentual, com el sector d'Aran en obstètrica o Barcelona Les Corts en altes mèdiques i quirúrgiques, corresponen a territoris amb volums relativament baixos o amb dinàmiques assistencials específiques, la qual cosa reforça la necessitat d'interpretar aquests resultats amb cautela i sempre en relació amb el context territorial.

En conjunt, l'anàlisi a nivell de sector sanitari mostra que el model global manté una capacitat predictiva raonable fins i tot en nivells territorials més desagregats, tot i que els resultats no poden ser considerats com a prediccions locals ajustades. Aquesta lectura multiescala resulta especialment útil com a eina de suport a la planificació sanitària, permetent identificar àrees on el comportament del model és més estable o, per contra, on pot ser necessari un anàlisi més específic.

Sols a nivell d'altes obstètriques caldria fer seguiment de 3 sectors, que superen en el model el 20 (sobre 200) de marge d'error sobretot tenint consideració en el sector Aran.

3.1.4. Resultats a nivell d'àrees de gestió assistencial (AGA)

Cal remarcar que els resultats obtinguts a nivell d'AGA tenen un caràcter estrictament orientatiu. El model ha estat entrenat amb dades agregades a nivells superiors i amb una finestra temporal limitada (sis anys d'entrenament i un any de validació), amb l'objectiu de capturar el comportament global del sistema hospitalari, i no dinàmiques específiques de cada àrea de gestió.

Pitjor SMAPE per tipus	Nom AGA	Valor (%)
Mèdica	Vallès Occidental Oest	17,21
Quirúrgica	Alt Urgell	19,61
Obstètrica	Alta Ribagorça	38,2

Els valors de SMAPE mostren, en la majoria d'AGA, errors percentuals moderats en les altes mèdiques i quirúrgiques, habitualment per sota del 10–12%. En canvi, les altes obstètriques presenten una major variabilitat, especialment en àrees amb un volum molt reduït d'activitat, on petites desviacions absolutes poden traduir-se en errors percentuals elevats.

Els casos amb pitjor rendiment percentual, com l'Alta Ribagorça en altes obstètriques o l'Alt Urgell en altes quirúrgiques, corresponen a àrees amb un nombre molt baix d'observacions, fet que reforça la necessitat d'interpretar aquests resultats amb cautela i sempre en relació amb el volum assistencial real.

En conjunt, l'anàlisi a nivell d'àrea de gestió assistencial posa de manifest que el model global manté una capacitat de generalització raonable fins i tot en nivells territorials molt desagregats, si bé els resultats no poden ser considerats com a

prediccions ajustades localment. Igual que a l'anterior apartat, utilitzem aquest enfocament multiescala per identificar territoris on el comportament del model és més estable o més volàtil, per la seva informació rellevant com a suport a la planificació sanitària.

Considerar si s'ha d'assignar recursos observant individualment les AGA, que superen el 20 sobre 200, totes de caràcter obstètric.

3.1.5. Resultats a nivell d'Àrees bàsiques de salut (ABS)

En aquest últim nivell, pel nombre de casos que implica tractar individualment les ABS una a una (nivell d'agregació més baix), havent realitzat un model que reculli tot el territori, s'ha d'indicar que la variabilitat és força major.

Pitjor SMAPE per tipus	Nom ABS	Valor (%)
Mèdica	Sant Cugat del Vallès - 2	64,37
Quirúrgica	Sant Cugat del Vallès - 2	37,61
Obstètrica	Alt Urgell Sud	58,27

En aquest cas, els models tenen un comportament acceptable tant en altes mèdiques com quirúrgiques, on el 90% dels casos és inferior a 20 sobre 200, però en les obstètriques el nombre que supera els 20, és del voltant del 20%, sempre degut a que estem parlant d'un nombre molt inferior d'ingressos per aquest darrer tipus.

Si que en aquest cas s'hauria de valorar territorialment que hi ha ABS que tenen un comportament força diferent, o millor dit on els resultats s'allunyen força dels reals i s'hauria d'analitzar observant altres característiques d'aquests territoris per potser tenir en compte una nova variable com a caràcter global. Per exemple, **l'ABS de Sant Cugat del Vallès – 2** és un cas interessant a estudiar individualment.

En conjunt, els resultats a nivell d'ABS confirmen que el model presenta un bon comportament global, especialment en l'activitat mèdica, mentre que l'activitat quirúrgica i, sobretot, l'obstètrica mostren una major dispersió en l'error. Aquest fet reforça la necessitat d'interpretar les mètriques de manera contextualitzada i justifica l'ús d'eines d'interpretabilitat, com l'anàlisi SHAP, per comprendre millor els factors que influeixen en les prediccions a escala territorial.

3.1.6. Robustesa dels models i adequació a l'objectiu de compra sanitària

Després d'analitzar les dades obtingudes, podem afirmar que l'ús de models de boosting amb hiperparàmetres optimitzats ha permès assolir un bon equilibri entre capacitat predictiva i generalització, evitant tant el sobre ajust com la pèrdua de sensibilitat davant patrons territorials rellevants.

Aquesta robustesa és especialment rellevant en el context del CatSalut, on la compra sanitària requereix:

- Estimacions fiables del volum global d'activitat,
- capacitat d'adaptació a diferències territorials,
- i eines que permetin incorporar criteris organitzatius i de governança més enllà de la predicció purament numèrica.

Els resultats obtinguts indiquen que el model compleix aquests requisits i constitueix una base sòlida per a la presa de decisions estratègiques en la planificació de la contractació hospitalària.

3.1.7. Conclusions finals (síntesi)

En conjunt, l'anàlisi dels resultats globals confirma que:

- El model presenta una elevada bondat d'ajust,
- les mètriques utilitzades són coherents amb els diferents nivells d'agregació,
- les limitacions identificades responen principalment a la naturalesa de les dades i no a deficiències estructurals del model,
- i la distribució prevista de la càrrega d'altres és consistent amb l'estructura territorial del sistema sanitari.

Això reforça la validesa del model com a eina de suport a la planificació sanitària i a la gestió de la compra d'activitat hospitalària dins la xarxa d'aguts.

3.2. Anàlisi d'interpretabilitat SHAP dels models

3.2.1. Motivació de la interpretabilitat en models predictius sanitaris

En l'àmbit de la planificació sanitària, l'ús de models predictius ha d'anar acompanyat de mecanismes que permetin comprendre i justificar-ne els resultats. A diferència d'altres dominis, les decisions basades en prediccions d'activitat hospitalària tenen implicacions organitzatives, pressupostàries i assistencials, la qual cosa exigeix transparència, traçabilitat i coherència epidemiològica.

Els models emprats en aquest treball (incloent-hi tècniques de regressió lineal i mètodes avançats basats en arbres de decisió i boosting) presenten un elevat rendiment predictiu, però també un grau de complexitat que dificulta la seva interpretació directa. Per aquest motiu, s'ha incorporat una anàlisi d'explicabilitat basat en la metodologia SHAP (SHapley Additive exPlanations), amb l'objectiu d'entendre com cada variable contribueix a les prediccions generades pels models. Seria el que s'anomena “**convertir una caixa negra en una caixa transparent**” (a nivell d'explicabilitat) [\(30\)](#).

3.2.2. Fonaments teòrics de SHAP

SHAP es basa en els valors de Shapley, un concepte procedent de la teoria de jocs cooperatius. En aquest marc teòric, un conjunt de jugadors coopera per obtenir un resultat comú, i els valors de Shapley permeten assignar de forma equitativa la contribució individual de cada jugador al resultat final.

Traslladat al context d'aprenentatge automàtic:

- El joc correspon a la predicció realitzada pel model.
- Els jugadors són les variables explicatives (features).
- El pagament és el valor de sortida del model (en aquest cas, el nombre d'altres hospitalàries previstes).

El valor SHAP d'una variable representa la seva contribució marginal mitjana a la predicció, calculada com la mitjana del seu impacte en totes les possibles combinacions de variables. Aquesta formulació garanteix propietats clau com:

- **Eficiència:** la suma dels valors SHAP coincideix amb la predicció del model.
- **Simetria:** variables amb el mateix efecte reben la mateixa contribució.
- **Absència de biaix:** una variable sense impacte real rep un valor nul.
- **Additivitat:** les contribucions individuals es poden sumar per explicar la predicció total.

Aquestes propietats converteixen SHAP en un marc teòricament sòlid i consistent per a la interpretabilitat de models complexos.

3.2.3. Interpretabilitat global: importància mitjana de les variables

La interpretabilitat global del model s'ha avaluat mitjançant l'anàlisi de la mitjana **del valor absolut dels valors SHAP** per a cada variable. Aquesta mètrica quantifica l'impacte mitjà de cada característica sobre la magnitud de la predicció i permet establir un rànquing d'importància.

Els resultats mostren que, en els tres models finals (altres mèdiques, quirúrgiques i obstètriques), destaquen dos grans grups de variables:

1. **Variables espacials**, representades per les coordenades del centre territorial (X, Y).
2. **Variables demogràfiques**, corresponents a les poblacions per grups d'edat quinquennals i sexe.

L'elevada importància dels centres confirma que la localització geogràfica actua com un factor estructural clau, capturant patrons territorials relacionats amb densitat poblacional, accessibilitat i pressió assistencial. Per la seva banda, les variables demogràfiques reflecteixen patrons epidemiològics coherents amb el tipus d'alta analitzada.

Analitzarem a tal efecte les variables en forma de *summary plot* i de manera absoluta amb barres.

3.2.4. Interpretabilitat local i anàlisi de dependència

A més de l'anàlisi global, SHAP permet explorar l'efecte d'una variable concreta sobre la predicció mitjançant els anomenats ***dependence plots***. Aquests gràfics representen la relació entre el valor d'una variable i la seva contribució al resultat del model, revelant:

- Relacions no lineals.
- Efectes de saturació o llindar.
- Interaccions implícites amb altres variables.

En aquest treball, per a cada tipus d'alta s'ha seleccionat la variable amb major pes global segons SHAP, i s'ha analitzat el seu comportament mitjançant un dependence plot. Aquesta aproximació permet il·lustrar de forma intuïtiva com petites variacions en variables clau (com la localització territorial o determinats grups d'edat) poden induir canvis significatius en l'activitat hospitalària prevista.

3.2.5. Valor afegit de SHAP per a la planificació sanitària

L'aplicació de SHAP aporta un valor afegit rellevant al model predictiu desenvolupat, ja que:

- Incrementa la **confiança** en els resultats del model.
- Facilita la **comunicació** amb perfils no tècnics (gestors, responsables de planificació).
- Permet validar que el model **captura relacions epidemiològicament plausibles**.
- **Reforça la governança de la dada**, en permetre auditar i justificar decisions basades en prediccions.

En conjunt, la incorporació de SHAP contribueix al fet que el model no només sigui precís, sinó també interpretable, alineant-se amb els principis de transparència i responsabilitat exigits en l'àmbit de la gestió sanitària pública.

3.2.6. Importància de les característiques

Veiem en primer cas les altes com s'han comportat les característiques envers les **altes mèdiques**. Recordem que s'ha utilitzat com algoritme predictiu el model XGBoost.




Figura 3-1 Importància de les característiques pel tipus d'alta mèdica

Podem veure com el nombre d'ingressos de dones entre 75 i 84 anys són el factor més decisiu pel model per assignar l'alta mèdica, també seguit pels homes entre 20 i 29 anys.

Per una altra banda, al ser els centroides de les característiques més importants, podem indicar que la localització geogràfica no actua com un simple factor lineal, sinó que captura heterogeneïtats territorials complexes, que poden estar degudes per la distribució (accessibilitat) dels serveis, la densitat de població o diferents comportaments de l'ús del sistema sanitari.

Seguim amb les **altes obstètriques**, que també han fet servir el model XGBoost.




Figura 3-2 Importància de les característiques pel tipus d'alta obstètrica

El aquest cas veiem que un augment de la població infantil impacta significativament en el nombre d'altres, igual que la població adulta jove (entre 25 i 39 anys, sobretot homes). Els centroides segueixen portant un pes important en l'assignació d'altres.

En resum, l'anàlisi SHAP del model XGBoost per a la predicció d'altres obstètriques mostra una estructura explicativa clarament diferenciada respecte a les altres mèdiques. La importància es concentra en variables demogràfiques associades a la natalitat recent i a la població en edat reproductiva, així com en la localització territorial. Els efectes observats són majoritàriament monòtons i amb menor dispersió, la qual cosa indica relacions més directes entre les característiques i la variable objectiu. Aquests resultats reforcen la coherència clínica i demogràfica del model i la seva utilitat per a la planificació específica de l'activitat obstètrica.

Altres quirúrgiques, que en aquest cas han utilitzat el model Gradient Boosting per a treballar les seves *features*.




Figura 3-3 Importància de les característiques pel tipus d'alta quirúrgica

En aquest cas, la distribució de l'edat és més transversal, tenint molt menys pes les variables infantils. Els centroides, segueixen estant entre les 15 primeres variables més importants, pel que segurament, pot influir on es realitza més activitat quirúrgica, no segueixen un patró lineal.

En resum sembla que hi ha una major heterogeneïtat clínica i organitzativa respecte a la resta de tipus d'alta.

Resum contrastant els tres tipus d'altres

- Les **altres mèdiques** presenten la major complexitat explicativa, dominada per la **població envellida** i amb **interaccions no lineals** rellevants.

- Les **altes obstètriques** mostren un patró concentrat i específic, vinculat a l'**estructura reproductiva i a la natalitat recent**.
- Les **altes quirúrgiques** reflecteixen un **model mixt**, condicionat tant per l'edat com per factors territorials i organitzatius.

De forma transversal, les variables geogràfiques actuen com a moduladors rellevants en els tres models, reforçant la importància de la dimensió territorial en la planificació sanitària.

3.2.7. Mapes de calor, comparativa a nivell global

He decidit realitzar uns mapes de calor per confrontar les diferències directes entre les característiques a cada model. M'ha semblat força interessant, ja que en diferents assignatures del grau, sobretot relacionades amb la mineria de dades, han aportat un valor afegit. En aquest cas s'omet incorporar mapes amb valor signat, ja que de per sí aquest es veurà molt significatiu.




Figura 3-4 Mapes de calor absolut de característiques dels 3 tipus d'alta

Podem concretar que aquest mapa de calor global dels valors SHAP absoluts permet visualitzar de forma comparativa la importància de les característiques entre els diferents tipus d'alta. S'observa una clara diferenciació de patrons: les altes mèdiques estan dominades per la població d'edat avançada, les obstètriques per indicadors de natalitat recent i estructura reproductiva, i les quirúrgiques per una combinació de població adulta activa i envellida. Aquest resultat reforça la coherència dels models i la seva adequació per a la planificació diferenciada de l'activitat hospitalària.

3.2.8. Mapes de calor, anàlisi SHAP per sexe (valor absolut)

Per incidir a la perspectiva de gènere aquests següents 2 apartats incorporen el pes de les variables segons sexe, en aquest primer cas, de manera absoluta.




Figura 3-5 Mapes de calor absolut per sexe pels 3 tipus d'alta

Altes mèdiques

En el cas de les altes mèdiques, el mapa de calor mostra una **concentració progressiva de la importància en edats avançades**, especialment en el col·lectiu de dones a partir dels 75 anys. Aquest patró és coherent amb l'augment de la morbiditat crònica i la major utilització dels serveis hospitalaris en edats avançades, així com amb diferències demogràfiques en esperança de vida entre sexes.

En els homes, tot i que la importància de les edats avançades també és rellevant, s'observa una distribució més homogènia al llarg de l'eix d'edats, amb contribucions destacables en edats adultes intermèdies (25 a 49 anys). Aquest

comportament suggereix una major dispersió dels factors explicatius associats a les altes mèdiques en el col·lectiu masculí.

Altes obstètriques

Tal com era esperable, el mapa corresponent a les altes obstètriques presenta una **concentració molt clara de la importància en dones en edat fèrtil i de la població infantil**, però també que els homes aporten més en un interval més ampli d'edat amb potencial reproductiu (20 a 44 anys). Aquest resultat valida empíricament el comportament del model i confirma que l'algoritme identifica adequadament la relació estructural entre edat, sexe i activitat obstètrica.

Altes quirúrgiques

Pel que fa a les altes quirúrgiques, el patró observat és més heterogeni. En els homes destaca una **contribució elevada en edats adultes joves i mitjanes**, especialment entre els 30 i els 34 anys, així com en alguns grups d'edat avançada. Aquest comportament podria estar associat a intervencions quirúrgiques de caràcter traumàtic o programat amb una major incidència en aquests trams d'edat.

En les dones, la importància es distribueix de manera més progressiva al llarg del cicle vital, amb pics rellevants tant en edats mitjanes com avançades (65–84 anys), suggerint una combinació de cirurgia programada i associada a patologies cròniques.

Valor interpretatiu global

En conjunt, aquest primer mapa de calor SHAP per sexe i valor absolut posa de manifest que:

- Els models capten patrons demogràfics clínicament plausibles, diferenciant adequadament el pes explicatiu de l'edat i el sexe segons el tipus d'alta.
- La importància de les variables d'edat no és uniforme, sinó fortament dependent del context assistencial (mèdic, quirúrgic o obstètric).
- L'anàlisi per sexe aporta una capa addicional d'interpretabilitat rellevant per a la planificació de la contractació sanitària, ja que permet identificar quins segments poblacionals tenen un impacte estructural més gran en la càrrega assistencial prevista.

Aquest enfocament reforça la utilitat dels valors SHAP com a eina d'explicabilitat global i prepara el terreny per a una anàlisi complementària basada en **mapes de calor amb valors SHAP signats**, que permetrà interpretar no només la magnitud, sinó també la direcció de l'impacte de cada variable sobre les prediccions.

3.2.9. Mapes de calor, anàlisi SHAP per sexe (valor signat)

Com a complement de l'anàlisi basada en la magnitud de la importància de les variables, s'ha construït un **segon mapa de calor utilitzant els valors SHAP signats**, per als tres tipus d'alta considerats. Aquest enfocament permet analitzar la direcció de l'impacte de cada variable sobre la predicció del model, és a dir, si un determinat grup poblacional contribueix a incrementar o a reduir el nombre d'altres estimades.




Figura 3-6 Mapes de calor signat per sexe pels 3 tipus d'alta

Abans de tot, aclarir que en les altes obstètriques, la **càrrega en les característiques està força concentrat** (rang -3 a 1) que si no s'observa bé pot donar peu a una mala interpretació.

Altes mèdiques

En el cas de les altes mèdiques, el mapa de calor mostra un **predomini de contribucions positives en edats adultes i avançades**, especialment en les dones de més de 75 anys, on els valors SHAP signats indiquen un increment clar de la predicció del volum d'altres. Aquest resultat és coherent amb la càrrega assistencial associada a l'envelliment poblacional i amb una major freqüència d'ingressos hospitalaris en aquests trams d'edat.

En els homes, s'observa una combinació de contribucions positives en edats joves i intermèdies, amb alguns trams d'edat (com els 40 - 44 anys) on la contribució és lleugerament negativa. Aquest comportament suggereix que, per a determinats segments masculins, l'efecte marginal sobre la predicció és més contingut o fins i tot compensatori respecte a altres variables del model.

Altes obstètriques

El mapa de calor corresponent a les altes obstètriques presenta un patró especialment clar i interpretable. En les dones en edat fèrtil, especialment entre els 25 i els 34 anys, els valors SHAP signats són **positius i elevats**, indicant que aquests grups contribueixen de manera significativa a augmentar la predicció d'altes obstètriques.

En canvi, tant en edats molt joves com en edats avançades, així com en el col·lectiu masculí, els valors SHAP són predominantment **negatius**, reflectint una contribució nul·la o reductora sobre la predicció. Aquest comportament reforça la consistència interna del model i la seva capacitat per captar restriccions estructurals del fenomen analitzat.

Altes quirúrgiques

Pel que fa a les altes quirúrgiques, el mapa de calor revela diferències rellevants entre sexes. En els homes, destaca una **contribució fortament positiva en el grup d'edat 65 - 69 anys**, que suggereix una associació significativa entre aquest segment poblacional i l'increment del volum d'altes quirúrgiques. També s'observen contribucions positives en edats adultes joves, tot i que amb menor intensitat.

En les dones, la contribució positiva és més progressiva i es concentra especialment en edats mitjanes i avançades (75 a 84 anys), mentre que en els grups d'edat més extrems s'observen valors negatius, indicant una menor aportació a la predicció global.

Interpretació conjunta amb el mapa de valors absoluts

La comparació entre els mapes de calor basats en **valors absoluts** i **valors signats** permet extreure conclusions complementàries. Mentre que el primer identifica quins grups poblacionals són estructuralment rellevants per al model, el segon permet discernir **si aquesta rellevància actua com a factor impulsor o moderador de la predicció**.

3.2.10. Partial dependence plots

Tal com s'ha comentat prèviament, aquest anàlisi es farà sobre el tipus de variable de més pes de cada tipus d'alta.

Comencem amb el PDP sobre la característica "**dones de 75 a 79 anys**" en les **altes mèdiques**:




Figura 3-7 PDP "Dones de 75 a 79 anys" pel tipus d'alta mèdica

La variable amb la que es fa interaccionar a la gràfica és **“homes de 20 a 24 anys”**.

Hi ha una clara tendència positiva de l'increment del nombre de dones amb el del valor SHAP per indicar la probabilitat d'alta mèdica, tal que coincideix amb la realitat clínica, ja que les persones grans tenen una major prevalença de les malalties cròniques.

Es curiosa la interacció on les ABS amb menor nombre d'homes entre 20-24 anys coincideix amb el menor valor SHAP de la variable de les dones de 70 a 79 anys, mentre que a l'extrem oposat, a les ABS on hi ha molts homes entre 20 i 24, el valor SHAP atribuït a la variable de les dones de 70 a 79 anys és força alt.

Per tant pot suggerir una correlació demogràfica o socioeconòmica entre les dues variables, pel que pot influir en la definició territorial i per tant, del model també.

PDP de les dones de 0 a 4 anys en altes obstètriques




Figura 3-8 PDP "Dones de 0 a 4 anys" pel tipus d'alta obstètrica

La variable amb la que interacciona és el de **les dones de 45 a 49 anys**.

També en aquest cas ens trobem amb una linealitat positiva, però més sinusoidal. El que sembla que ens està indicant la gràfica és el nivell de fertilitat de la zona, que està força relacionat per una banda amb el nombre de nenes que hi ha a l'ABS i per altra banda que està força relacionat amb que segurament les dones de 45 a 49 anys són les generadores correlacionades d'aquest valor SHAP.

Observem com altra element interessant el fet de que a les zones que els hi atorga més valor SHAP (al voltant de 50) està a prop de les ABS amb una població al voltant de 1200 nenes, que no són necessàriament els llocs amb població més alt.

PDP dels homes de 30 a 34 anys en les altes quirúrgiques




Figura 3-9 PDP "Homes de 30 a 34 anys" pel tipus d'alta quirúrgica

La variable amb la que interacciona són les **dones de 50 a 54 anys**.

En aquest cas la tendència (contra més homes més valor SHAP) no és sols clarament positiva, sinó que també és força pronunciada. El que pot voler significar és que els homes entre 30 i 34 anys tenen una major probabilitat de generar altes quirúrgiques, però segurament deguts a riscos laborals o esportius, s'haurien d'avaluar els diagnòstics per traumatismes que podrien ser els generadors o factor que fes que aquesta variable fos tant important per el model.

Hi ha una interacció directa amb el nombre de dones de entre 50 i 54 anys, encara que és força arriscat d'interpretar el motiu d'aquesta interacció, podent ser erròniament d'una possible relació familiar directa, o senzillament d'una estructura de població estable.

3.2.11. Aportació de cada variable (waterfall)

En aquest cas també ens centrarem en un cas per cada tipus d'alta i, per ser crítics, serà en la característica que en cada cas ha obtingut el pitjor SMAPE.

Comencem amb l'ABS de Sant Cugat del Vallès – 2 al tipus d'alta mèdica.

Aportació de cada variable (*waterfall*) per obtenir les altes de tipus 'Mèdica' per l'ABS Sant Cugat del Vallès - 2




Figura 3-10 Aportació a l'ABS de mostra pel tipus d'alta mèdica

El que ens indica aquesta gràfica, és que per calcular el valor final **1140,274** ha partit des de el valor base de 938,233, sent la variable de **les dones de 75 a 79 anys**, amb 680 persones, **la que més aporta amb +174,74 punts sobre el resultat final**.

La variable que incideix més negativament és la de les dones de 55 a 59 anys amb una reducció de -122,48 a l'aportació final de l'ABS.

Hi ha 3 variables força importants també (més que la resta de negatives individualment), que son els homes entre 25 i 29 anys, els homes entre 75 i 79 anys i els homes de 80 a 84 anys.

Analitzem també l'ABS de Sant Cugat del Vallès – 2 pel tipus d'alta quirúrgica




Figura 3-11 Aportació a l'ABS de mostra pel tipus d'alta quirúrgica

En aquest cas el valor base del que es parteix és el de 1144,879 i el valor final que obtenim per l'ABS és de **1599,289** de predicció d'altres quirúrgiques, sent la variable **dels homes de 65 a 69 anys**, amb 904 persones, **la que més aporta amb +279,41 punts sobre el resultat final**.

La variable que incideix més negativament és la de les dones de 95 o més anys amb una reducció de -137,9 a l'aportació final de l'ABS, sent aquesta més gran que la resta de reduccions a l'aportació final.

Per sobre de la següent característica amb aportació negativa, ens trobem les dones de 65 a 69 anys, els homes de 30 a 34 anys, els homes de 45 a 49 anys, les dones de 25 a 29 anys i les dones de 75 a 79 anys.

En resum es pot dir que tenim 35 característiques que redueixen valor a l'impacte del nombre d'altres quirúrgiques, però les 7 restants incideixen amb força positiva sobre el resultat final.

Finalment pel tipus d'alta obstètrica, analitzem l'ABS Alt Urgell Sud




Figura 3-12 Aportació a l'ABS de mostra pel tipus d'alta obstètrica

En aquest darrer cas, partint del valor base 121,458 s'arriba al valor final de **21,867** altes obstètriques, sent els **115 homes de 30 a 34 anys** els que més impacte tenen però de manera negativa, amb **-25,62 punts**.

Aquí hem de prestar atenció a com el model actua. Parteix d'un model base força gran (almenys per l'ABS), però sent tot aquest valor contrarestat per la incidència negativa de les variables.

També cal observar que en aquest cas **els centroides han estat un factor decisiu** a l'hora d'aportar el valor d'altes obstètriques al conjunt de l'ABS.

3.3. Resum final de tota la interpretació

Aquest apartat també s'entregarà a manera d'informe-document a la institució com a valoració de tota la informació recollida i analitzada.

L'estudi realitzat permet concloure que el model predictiu desenvolupat presenta un alt nivell de consistència, robustesa i interpretabilitat en tots els nivells d'agregació analitzats, des del nivell global, passant per les Regions Sanitàries, fins arribar a les Àrees Bàsiques de Salut (ABS), assolint els objectius plantejats en el marc de la planificació de la contractació sanitària dins la xarxa hospitalària d'aguts.

3.3.1. Comportament de les mètriques segons el nivell d'agregació

A nivell global, els resultats mostren una **elevada bondat d'ajust**, amb coeficients de determinació (R^2) superiors a 0,93 en tots els tipus d'alta, indicant que el model és capaç de capturar la major part de la variabilitat de l'activitat assistencial. Les mètriques d'error absolut (MAE i RMSE) presenten valors baixos en relació amb el volum total d'altres, fet que reforça la fiabilitat del model per a la planificació agregada de recursos.

A mesura que s'incrementa la granularitat de l'anàlisi (sectors sanitaris, AGA i ABS), s'observa un augment progressiu de l'error relatiu, especialment quan es mesura mitjançant el SMAPE. Aquest comportament és esperable i respon principalment a la **limitació inherent de les dades en unitats amb baixa activitat absoluta**, on petites desviacions en valors absoluts poden traduir-se en errors percentuals elevats. Cal recordar que el SMAPE pot assolir valors entre 0% i 200%, de manera que els resultats observats, fins i tot en els casos més desfavorables, es mantenen dins d'uns marges interpretables i coherents amb el context assistencial.

En aquest sentit, l'anàlisi a nivell d'ABS confirma que el model **manté una estructura predictiva estable**, tot i que la precisió puntual pot variar segons el volum i la tipologia d'activitat, sense comprometre **l'objectiu principal de l'estudi: la correcta distribució territorial de la càrrega assistencial**.

3.3.2. Robustesa del model i adequació a l'objectiu de planificació

La comparació entre diferents famílies de models i la posterior selecció de tècniques de *boosting* amb hiperparàmetres optimitzats ha permès assolir un **equilibri adequat entre capacitat predictiva i generalització**. Aquesta robustesa es reflecteix en la coherència dels resultats entre nivells d'agregació i en la capacitat del model per adaptar-se a escenaris amb dades heterogènies.

Des del punt de vista de la compra sanitària, el model no s'orienta a la predicció exacta de cada ABS de manera individual, sinó a la **captura fiable de la distribució global de la càrrega d'altres** en funció de la proximitat a la població i l'estructura territorial del sistema sanitari. En aquest context, les mètriques obtingudes avalen l'ús del model com a eina de suport a la presa de decisions estratègiques.

3.3.3. Contribució de l'anàlisi SHAP a la interpretació dels resultats

L'anàlisi d'interpretabilitat mitjançant SHAP aporta una capa qualitativa clau per entendre el comportament del model més enllà de les mètriques numèriques. Les gràfiques globals mostren una **distribució coherent de la importància de les variables**, amb patrons estables entre tipus d'alta i segments poblacionals, fet que reforça la credibilitat del model.

Els mapes de calor, tant en valor absolut com signat, evidencien que les variables amb major impacte són consistents amb el coneixement del domini sanitari i amb

l'organització territorial del sistema. Això permet confirmar que el model **no es basa en relacions “sintètiques”**, sinó que aprèn patrons estructurals relacionats amb la població, la demanda assistencial i la distribució territorial.

A nivell de subgrups (com el sexe), les diferències observades en les contribucions de les variables aporten informació rellevant per a futures anàlisis, però sense alterar de manera significativa la capacitat predictiva global del model, la qual es manté estable.

3.3.4. Conclusió final

En conjunt, la combinació de mètriques quantitatives sòlides i eines d'interpretabilitat com SHAP permet concloure que el model desenvolupat és **tècnicament robust, explicable i adequat per a l'ús organitzatiu** per al qual ha estat dissenyat. Les limitacions detectades responen principalment a la naturalesa i granularitat de les dades, i no a deficiències estructurals del model, podent tenir unes prediccions més precises si s'utilitzen dades de projeccions, preparades pels propis equips del CatSalut.

Així, el model constitueix una **base fiable per a la planificació de la contractació sanitària**, permetent anticipar la distribució futura de l'activitat hospitalària d'aguts i facilitant una gestió més informada, coherent i alineada amb l'estructura territorial del sistema de salut.

4. Conclusions i treballs futurs

4.1. Conclusions generals del treball

L'objectiu principal d'aquest Treball de Fi de Grau ha estat el desenvolupament d'una eina predictiva basada en dades per a la previsió anual de l'activitat hospitalària d'aguts, concretament d'altres mèdiques, quirúrgiques i obstètriques, amb la finalitat de donar suport a la planificació i contractació sanitària dins l'estructura del Servei Català de la Salut.

Un cop obtinguts els resultats, es pot concloure que els models predictius desenvolupats presenten un **alt nivell de capacitat explicativa i predictiva**, amb valors de coeficient de determinació R^2 superiors a 0,92 a nivell global i un comportament estable en els diferents nivells d'agregació analitzats. Aquests resultats confirmen que les variables seleccionades i el tractament de les dades han estat suficients per capturar els patrons subjacents de l'activitat hospitalària i la representativitat territorial.

En termes generals, els resultats obtinguts han estat **coherents amb les expectatives inicials**, especialment pel que fa a la capacitat dels models de tipus *boosting* per gestionar relacions no lineals i interaccions complexes entre variables. No obstant això, alguns resultats han estat especialment rellevants, com ara el pes explicatiu de les característiques geogràfiques (centroïdes), que han mostrat una influència més marcada del que es preveia inicialment. Aquest fet reforça que el producte obtingut es pot fer servir per predir la càrrega territorial d'àrees bàsiques de salut que no s'hagin tingut en compte a l'hora de d'entrenar el model.

La part positiva de no haver utilitzat sèries temporals, ha estat obtenir un producte que el que avalua és la càrrega que pot produir depenent del territori i de la població, en qualsevol hipotètic moment.

L'ús d'una puntuació mitjançant ponderació de mètriques li ha donat robustesa al model reduint l'impacte dels biaixos en general.

La incorporació de tècniques d'interpretabilitat, com l'anàlisi SHAP, ha permès no només validar els resultats obtinguts, sinó també aportar transparència i traçabilitat a les prediccions, aspectes clau en un context de presa de decisions públiques.

El fet d'afegir una interfície gràfica basada en text, facilita el desplegament de la solució com a eina amigable i d'uns habitual.

Com a part negativa, s'evidencia una disminució de rendiment del model en els nivells més baixos d'agregació, possiblement degut al nombre de sèries disponibles en el moment de desenvolupar l'aplicació. S'hauria acceptat també

un coeficient de determinació (explicació de la variabilitat) una mica inferior i que el nivell hagués estat superior en el seu mínim nivell d'agregació.

4.2. Assoliment dels objectius plantejats

Pel que fa a l'assoliment dels objectius definits a l'inici del treball, es pot afirmar que **s'han assolit de manera satisfactòria els objectius principals i la major part dels objectius específics**.

En concret:

- S'ha desenvolupat un model predictiu robust per a la previsió d'altres hospitalàries d'aguts.
- S'ha aplicat una metodologia estructurada basada en CRISP-DM adaptada al context sanitari.
- S'ha integrat l'anàlisi d'interpretabilitat per facilitar la comprensió dels resultats.
- S'ha respectat la privacitat i el caràcter sensible de les dades a l'haver treballat amb dades agregades, tant en les característiques com en les variables objectiu, on podríem haver incidit en els diagnòstics enlloc del tipus d'alta.
- S'ha implementat un frontend de treball per tal de poder fer l'eina més propera a l'ús dins del context organitzatiu.

Alguns objectius secundaris, com l'exploració de models alternatius més avançats (per exemple, enfocaments d'aprenentatge profund o sèries temporals amb major granularitat), no s'han pogut desenvolupar en profunditat a causa de limitacions temporals i de disponibilitat de dades. Tot i això, aquestes limitacions no comprometen l'assoliment de l'objectiu principal del treball, sinó que obren línies clares de treball futur.

4.3. Seguiment de la planificació i adequació de la metodologia

L'execució del treball **s'ha ajustat de manera general a la planificació inicial prevista**. Tot i això, com és habitual en projectes de dades reals, ha estat necessari **introduir ajustos i refinaments** al llarg del procés, especialment a la fase de preparació de les dades, degut a la seva heterogeneïtat de fonts i de la manera que han estat emmagatzemades en èpoques diferents.

La metodologia CRISP-DM adaptada ha demostrat ser **adequada i flexible** per al tipus de projecte desenvolupat, permetent iterar entre fases i incorporar millores progressives sense comprometre la coherència global del treball. En particular, la fase de modelatge ha requerit iteracions addicionals per optimitzar hiperparàmetres i validar la robustesa dels models.

Aquests ajustos no només han estat necessaris, sinó que han contribuït a garantir la qualitat final del producte, posant de manifest la importància de concebre la planificació com un procés dinàmic i adaptable, especialment en projectes aplicats a l'àmbit sanitari.

Els ajustos més importants, encara que no han afectat en canvis significatius en la planificació han estat el canvi amb la recollida de variables a l'inici i la implantació d'una interfície d'execució al final.

4.4. Avaluació dels impactes ètic-socials, de sostenibilitat i de diversitat

Cal remarcar que en relació als objectius generals en relació a l'Agenda 2030 de Desenvolupament Sostenible. Sols hem avaluat el punts en concret que afectaven a l'execució d'aquest Treball Final, ja que cada tipus de treball, en cada àrea / branca d'estudi, aprenentatge o execució, no recorren tot l'abast del punts planificats a l'Agenda, ja que poden ser força específics.

En relació amb els impactes identificats a l'apartat 1.3, es pot concloure que **els riscos potencials han estat adequadament mitigats** i que els impactes positius previstos s'han assolit en gran mesura.

Des del punt de vista ètic i social, l'ús de dades agregades i anonimitzades ha permès minimitzar riscos relacionats amb la privacitat i la confidencialitat. A més, la incorporació de tècniques d'interpretabilitat contribueix a reduir l'opacitat dels models i a fomentar una presa de decisions més responsable i transparent.

Pel que fa a la sostenibilitat, el model proposat facilita una millor planificació de recursos, contribuint potencialment a un ús més eficient dels recursos sanitaris i a una reducció de costos associats a infraestructures i contractació inadequada.

En relació amb la diversitat i l'equitat territorial, l'anàlisi en diferents nivells d'agregació permet detectar possibles desequilibris i proporciona una base objectiva per a una planificació més equitativa, tot i que aquest aspecte podria ser aprofundit en futurs treballs.

4.5. Impactes no previstos

El principal impacte negatiu ha estat el del nombre de sèries a treballar. El fet de que la predicció hagi de ser de caràcter anual i que sols s'ha pogut accedir a dades complertes des del 2018, ha generat un enfocament diferent al previst inicialment, amb el que es descartava fer servir eines d'aprenentatge profund (com les xarxes LTSM) i o sèries temporals per acotar a quins territoris en quins moments es produeix major càrrega assistencial.

Com impacte positiu, ha estat el fet de treballar amb centroides, amb el que s'aconsegueix predir en qualsevol part del territori, tenint una determinada càrrega de població, quina seria la càrrega d'altres hospitalària requerida.

Altra impacte ha estat la bona acollida del desplegament d'una interfície, que encara que el mèrit del disseny pugui haver estat part de la tasca desenvolupada, no hem d'oblidar que ha estat el director del treball- tutor, el que ha suggerit aquesta implementació en el producte final.

4.6. Línies de treball futur

Finalment, es proposen diverses línies de treball futur que podrien ampliar i millorar els resultats obtinguts:

- El més important de tot seria la separació del preprocés de les projeccions poblacionals, que sorgís directament de les unitats dins del CatSalut / Departament de Salut, que actualment s'encarreguen d'aquesta tasca. De la mateixa manera, en aquest preprocés s'hauria d'incloure la projecció geogràfica de la població.
- Ampliar el conjunt de variables amb factors socioeconòmics o epidemiològics.
- Avaluar també la incorporació de quines variables de projecció climàtica (per exemple, temperatures mínima - màxima – mitjana, o precipitacions), puguin ser interessants incorporar al model.
- Incorporar una major granularitat temporal (mensual o trimestral) per millorar la capacitat de planificació operativa.
- Explorar models basats en sèries temporals i aprenentatge profund, com ara xarxes LSTM, en combinació amb els models actuals.
- Millora de la interfície interactiva, ja que ha estat implementada en la part final del desenvolupament i hi ha aspectes com el disseny responsiu que es poden millorar, encara que la interfície gràfica sigui en format text.
- Aprofundir en l'anàlisi d'equitat territorial i possibles biaixos del model.
- Integrar el model dins d'un entorn productiu de suport a la decisió del CatSalut.

Aquestes línies obren la porta a la continuïtat del treball i reforcen el seu potencial impacte real en la planificació sanitària.

5. Glossari

ABS	Àrea Bàsica de Salut
AGA	Àrees de Gestió Assistencial
Agregació	Operació matemàtica per resumir dades (en aquest treball és el recompte).
API	Interfície de programació d'Aplicacions
AUC	Àrea sota la corba
Boosting	Models d'aprenentatge automàtic basats en arbres de decisió
CatSalut	Servei Català de la Salut
Centroide	Parell de coordenades geogràfiques o d'un polígon (x, y)
Contenedor	Paquet de programari amb tot el codi necessari per funcionar
CRISP-DM	Cross-Industry Standard Process for Data Mining
csv	Fitxer tabular de dades separades per comes.
DAFO (taula)	Taula de Debilitats, Amenaces, Fortaleses i Oportunitats
EAP	Equip d'Atenció Primària assignat a l'usuari
Feature importance	Importància de les variables explicatives o característiques
Fork	Còpia independent d'un projecte per desenvolupar-lo per separat
Frontend	Interfície de control i execució
GPU	Graphics Processing Unit, unitat de processador de gràfics
Granularitat	Nivell d'agregació, pot ser temporal, geogràfic, etc.
ICS	Institut Català de la Salut
Idescat	Institut d'Estadística de Catalunya
Lag features	Variables creades a partir de valors passats per capturar la dependència
Machine learning	Aprenentatge automàtic
MAE	Mètrica de l'Error Absolut Mitjà
Mètrica	Indicador quantitatiu del rendiment d'un model.
R^2	Mètrica del Coeficient de Determinació
RCA	Registre Central d'Assegurats (població del CatSalut)
RMSE	Mètrica de l'Arrel de l'Error Quadràtic Mitjà
Rolling-training	Entrenar un model afegint dades d'un període següent.
Score	Puntuació global derivada de la combinació ponderada de mètriques.
SHAP	Eina per interpretar models predictius (SHapley Additive Explanations)
SMAPE	Mètrica de l'Error Percentual Absolut Mitjà Simètric.
TUI	Interfície Gràfica Textual (per a un programari)
xlsx	Fitxer en format Microsoft Excel per treballar dades, principalment en format tabular.

6. Bibliografia

1. Sistema sanitari català i qualitat assistencial [Internet]. CatSalut. Servei Català de la Salut. [Consultat 9 maig 2025]. Disponible a: <http://catsalut.gencat.cat/ca/coneix-catsalut/acces-sistema-salut/assistencia-transfronterera/que-es/sistema-sanitari/>
2. CatSalut. Clàusula 2023 Hospital Sant Joan de Déu de Manresa [Internet]. Gencat.cat. [Consultat 9 maig 2025]. Disponible a: https://catsalut.gencat.cat/web/.content/minisite/catsalut/proveidors_professionals/contractacio_serveis_assistencials/registre_convenis_contractes/relacio/AES/Clausules-20230101-AES-AlthaiaXAUMFPriv-HStJoanDeuManresa-671700412-G58286303.pdf
3. Resolució de condicions generals de contractació 2024 [Internet]. Gencat.cat. [Consultat 9 maig 2025]. Disponible a: https://catsalut.gencat.cat/web/.content/minisite/catsalut/proveidors_professionals/contractacio_serveis_assistencials/registre_convenis_contractes/relacio/resolucio-condicions-generals-contractacio-2024.pdf.pdf#:~:text=ESPECIALITZADA.%20ACTIVITAT%20I%20SISTEMA
4. CatSalut. Clàusula 2022 Consorci Hospitalari de Vic [Internet]. Gencat.cat. [Consultat 9 maig 2025]. Disponible a: https://catsalut.gencat.cat/web/.content/minisite/catsalut/proveidors_professionals/contractacio_serveis_assistencials/registre_convenis_contractes/relacio/AES/Clausules-20220101-AES-ConHospVic-HGenVic-671701312-Q5856102H.pdf
5. Sindicatura de Comptes de Catalunya. Sistema de contraprestació dels serveis d'atenció hospitalària i especialitzada d'aguts prestats pels centres del SISCAT per compte del CatSalut, exercici 2022. Informe 5/25 [Internet]. Gencat.cat. [Consultat 12 novembre 2025]. Disponible a: <https://www.sindicatura.cat/-/5/2025-sistema-de-contraprestaci%C3%B3-dels-serveis-d-atenci%C3%B3-hospital%C3%A0ria-i-especialitzada-d-aguts-prestats-pels-centres-del-siscat-per-comptes-del-catsalut-exercici-2022>
6. MIMIC The medical information mart for intensive care [Internet]. Mímic.mit.edu. [Consultat 2 juny 2025]. Disponible a: <https://mimic.mit.edu/>
7. Johnson A, Pollard T, Mark R. MIMIC-III clinical database [Internet]. PhysioNet; 2015 [Consultat 2 juny 2025]. Disponible a: <https://physionet.org/content/mimiciii/1.4/>
8. Su D, Zheng J, Shao Y, Liu J, Liu X, Yu K, et al. Developing and validating a machine learning-based model for predicting in-hospital mortality among ICU-admitted heart failure patients: A study utilizing the MIMIC-III

- database. DIGITAL HEALTH [Internet]. 2025 Apr. [Consultat 2 juny 2025]. Disponible a: <https://pubmed.ncbi.nlm.nih.gov/40297352>
- 9 Soffer S, Klang E, Barash Y, Grossman E, Zimlichman E. Predicting In-Hospital Mortality at Admission to the Medical Ward: A Big-Data Machine Learning Model. *The American Journal of Medicine*. 2021 Feb;134(2):227-234.e4.
 - 10 Li F, Xin H, Zhang J, Fu M, Zhou J, Lian Z. Prediction model of in-hospital mortality in intensive care unit patients with heart failure: machine learning-based, retrospective analysis of the MIMIC-III database. *BMJ Open* [Internet]. 2021 Jul 23 [Consultat 2 juny 2025];11(7):e044779. Disponible a: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8311359/>
 - 11 Rahimian F, Salimi-Khorshidi G, Payberah AH, Tran J, Ayala Solares R, Raimondi F, et al. Predicting the risk of emergency admission with machine learning: Development and validation using linked electronic health records. Sheikh A, editor. *PLOS Medicine*. 2018 Nov 20;15(11):e1002695.
 - 12 Brossard C, Goetz C, Catoire P, Cipolat L, Guyeux C, Gil Jardine C, et al. Predicting emergency department admissions using a machine-learning algorithm: a proof of concept with retrospective study. *BMC Emergency Medicine* [Internet]. 6 gener 2025 [Consultat 2 juny 2025];25(1):3. Disponible a: <https://doi.org/10.1186/s12873-024-01141-4>
 - 13 Nuthakki S, Neela S, Gichoya JW, Purkayastha S. Natural language processing of MIMIC-III clinical notes for identifying diagnosis and procedures with neural networks [Internet]. arXiv; 2019 [Consultat 2 juny 2025]. Disponible a: <http://arxiv.org/abs/1912.12397>
 - 14 Huang Y, Xu C, Ji M, Xiang W, He D. Medical service demand forecasting using a hybrid model based on ARIMA and self-adaptive filtering method. *BMC Med Inform Decis Mak* [Internet]. 19 setembre 2020 [Consultat 4 juny 2025]; 2020;20(1):237. Disponible a: <http://dx.doi.org/10.1186/s12911-020-01256-1>
 - 15 Zhou L, Zhu Q, Chen Q, Wang P, Huang H. Predicting hospital outpatient volume using XGBoost: a machine learning approach. *Sci Rep* [Internet]. 16 maig 2025. [Consultat 5 octubre 2025]; 15(1):17028. Disponible a: <https://www.nature.com/articles/s41598-025-01265-y>
 - 16 Tello M, Reich ES, Puckey J, Maff R, Garcia-Arce A, Bhattacharya BS, et al. Machine learning based forecast for the prediction of inpatient bed demand. *BMC Med Inform Decis Mak* [Internet]. 2 març 2022. [Consultat 4 juny 2025]; 2022;22(1):55. Disponible a: <http://dx.doi.org/10.1186/s12911-022-01787-9>

- 17 Klunder JH, Panneman SL, Wallace E, de Vries R, Joling KJ, Maarsingh OR, et al. Prediction models for the prediction of unplanned hospital admissions in community-dwelling older adults: A systematic review. PLoS One [Internet]. 23 setembre 2022. [Consultat 4 juny 2025] 2022;17(9):e0275116. Disponible a: <http://dx.doi.org/10.1371/journal.pone.0275116>
- 18 Servei Català de la Salut. Atenció especialitzada i hospitalària d'aguts [Internet]. Barcelona: Generalitat de Catalunya; [consultat el 09 d'abril de 2025]. Disponible a: <https://catsalut.gencat.cat/ca/serveis-sanitaris/atencio-especialitzada-hospitalaria-aguts/>
- 19 Birch S, Kephart G, Tomblin-Murphy G, O'Brien-Pallas L, Alder R, MacKenzie A. Human resources planning and the production of health: a needs-based analytical framework. Canadian Public Policy. 2007;33(S1):S1–S16
- 20 Fundació "la Caixa". La situació a Espanya: cronicitat i població gran. Observatori Social de "la Caixa" [Internet]. 2021 [consultat el 08 d'abril de 2025]. Disponible a: <https://elobservatoriosocial.fundacionlacaixa.org/ca/-/la-situaci%C3%B3-a-espanya-2>
- 21 Parlament de les Illes Balears. L'envelliment de la població a les Illes Balears. Servei d'Estudis i Documentació Parlamentària [Internet]. 2022 [consultat el 08 d'abril de 2025]. Disponible a: <https://www.parlamentib.es/FileHandler/Publica--9--altres/EnvellimentIB>
- 22 Institut d'Estadística de Catalunya (IDESCAT). Naixements segons lloc de residència de la mare [Internet]. Barcelona: IDESCAT; 2024 [consultat el 8 d'abril de 2025]. Disponible a: <https://www.idescat.cat/indicadors/?id=anuals&n=10342>
- 23 Departament d'Economia i Hisenda – Generalitat de Catalunya. Demografia: natalitat, mortalitat, saldo migratori [Internet]. Barcelona: economia.gencat.cat; 2024 [consultat el 8 d'abril de 2025]. Disponible a: <https://economia.gencat.cat/ca/ambits-actuacio/economia-catalana/trets/demografia-capital-huma-benestar/demografia/>
- 24 The R Project for Statistical Computing [Internet]. R-project.org. [consultat el 10 d'abril de 2025]. Disponible a: <https://www.r-project.org/>
- 25 Welcome to Python [Internet]. Python.org. [consultat el 10 d'abril de 2025]. Disponible a: <https://www.python.org/>
- 26 KNIME Analytics Platform [Internet]. KNIME. [consultat el 12 d'abril de 2025]. Disponible a: <https://www.knime.com/knime-analytics-platform>
- 27 Java|Oracle [Internet]. Java.com. [consultat el 15 de juny de 2025]. Disponible a: <https://www.java.com/en/>

- 28 BarD Software s. r. o. GanttProject: free project management tool for Windows, macOS and Linux [Internet]. GanttProject. [consultat el 4 d'octubre de 2025]. Disponible a: <https://www.ganttproject.biz/>
- 29 Lundberg S, Lee S-I. A unified approach to interpreting model predictions [Internet]. arXiv [cs.AI]. 2017. [consultat el 12 de gener de 2025]. Disponible a: <http://arxiv.org/abs/1705.07874>
- 30 Molnar C. Interpretable machine learning [Internet]. Github.io.[consultat el 18 de maig 2025]. Disponible a: <https://christophm.github.io/interpretable-ml-book/>

7. Annexos

Annex A. Recomanacions del director del treball - tutor

El meu tutor acadèmic, Alfons Marquès i Cancio, sempre ha format una part activa en l'acompanyament, no sols en el seguiment sinó també des de la pluja inicial de idees per la selecció del Treball, tota la contextualització i la preparació de la solució.

A continuació exposo moltes de les recomanacions o indicacions que ha anat suggerint, per tenir en compte o implantar en la solució final.

La primera recomanació de totes va ser quan el que es perfilava l'àrea (dades sanitàries) però no encara l'objecte en si. Tenir cura amb les dades, ja que en el sector sanitari moltes dades s'introdueixen manualment i no estan estandarditzades.

Sempre “tenir un pla B”. El primer com que es va suggerir va ser si finalment es complicava l'accés a dades internes, una bona alternativa seria accedir a *PhisioNet* o *Kaggle*.

El tutor sempre ha volgut transmetre cautela amb les pretensions: “L'abast del projecte s'ha de clarificar a partir de les dades disponibles”. Sempre s'ha de tenir present amb el que realment es compta.

Altra recomanació ha estat la definició de l'estructura, definint el 4 grans trets principals clau que havia de contenir el treball (justificació, definició, metodologia i aplicabilitat).

En concret sobre la part metodològica, va fer la proposta sobre les tècniques a utilitzar (sèries temporals, models de classificació i regressió, i optimització de recursos). El treball final ha estat basat en models de regressió, tant amb regressions lineals com tècniques de *boosting*.

En passos posteriors, les recomanacions es van concretar sobre aprofundir en els aspectes organitzatiu, tècnic i metodològic, sent aquest el primer cop que es va suggerir com abordar el tema de la interpretabilitat.

També es va recomanar afegir algun risc operatiu, ja que sempre i quan el projecte ha de formar part d'un conjunt (altres tasques, persones), implica dependències i imprevistos.

Un altra de les recomanacions sobre l'entrega del programari va ser que no sols és centrés a l'entrega dels scripts finals sinó que també aportés els notebooks intermedis amb els quals vaig estar treballant preparant la solució.

I, potser la recomanació més important de totes va ser la de la interfície de treball. Aquest producte està basat en una sèrie de scripts que s'executen

successivament des de consola. Però el tutor va considerar com un afegit molt útil al projecte, implementar un “frontend”, ja que si vols que una eina s'utilitzi, has de fer que sigui fàcil de fer-la servir.

La darrera recomanació va ser sobre la reducció de variables globals, que vaig descartar, per ajudar a facilitar l'execució dels scripts des de diferents rutes i del frontend, sent les variables més accessibles directament.